

從顧客分群到再購預測： 結合RFM與機器學習 之LTV分析

113-2 大數據與商業分析 第五組

經濟四

圖資碩二

生醫電資碩二

財金三

王乙軒、闕蕎蓁、姚力瑋

蔡馨頤

王仁宏

鄭凱元

影片連結：<https://youtu.be/S6QMAMdHVlc?feature=shared>



報告大綱

01

提案動機與研究目標

02

資料說明與資料前處理

03

顧客分群與潛力識別

04

消費關鍵因子分析

05

再購機率預測與 LTV 模型建置

06

總結與討論

01

提案動機與研究流程

提案動機

對於電商來說，如何區分不同顧客並採取相應策略，一直是經營上的關鍵議題。其中，最常見的方式包括 RFM 模型，也就是根據「最近消費時間」、「消費頻率」和「單次消費金額」這三個指標，對顧客進行靜態分類。儘管 RFM 模型具有操作簡單的優勢，卻難以捕捉顧客差異與潛在價值，進而影響行銷資源的精準配置與應用效益。

為突破上述限制，本組提出一套整合性的資料分析方法。我們先以 RFM 特徵進行 K-means 分群，建立顧客行為輪廓；再針對各群顧客分別建構線性迴歸與 XGBoost 模型，找出影響再購的關鍵因素，並預測再購機率和消費金額，進一步算出每位顧客的終身價值（LTV），以幫助企業做出更有效的行銷決策。

研究流程

1. 透過 IQR 法過濾離群值，強化資料品質與後續模型穩定性
2. 利用 RFM 特徵進行 K-means 分群 (elbow method) 以建構顧客輪廓，提升會員識別準確度
3. 應用線性迴歸與 XGBoost 模型，辨識影響再購與消費金額的關鍵因素
4. 建構分類與迴歸模型，預測顧客的再購機率與預期消費金額
5. 綜合預測結果推估顧客終身價值 (LTV)，最佳化行銷資源分配與經營決策

02

資料說明與資料前處理

資料說明

- 使用之資料集

會員資料

主單資料

- 訓練集時間跨度：2022/01/01-2023/06/30，共18個月
- 預測集時間跨度：2023/07/01-2024/02/29，共8個月
- 基準日：2023/06/30（訓練集最後一日）

使用資料欄位

會員資料變數

性別、生日（年齡）、註冊來源、會員卡等級、通知管道（Email、推播、簡訊）

主單資料變數

通路明細（App / Web / 線下）、訂單總金額（含折扣）、付款方式、折扣使用情形

資料前處理與離群值過濾

原始資料

去除缺失值

特徵提取

1.5 倍 IQR 法
剔除離群值

e.g. 消費金額為0、
性別欄位空值等等

e.g. 透過Birthday建立 Age，以及將
MemberCardLevel
分為是否為10~30、
40~60區間

移除極端值，避免影
響分群與模型建構
(也考量過使用
Isolation Forest)

03

顧客分群與潛力識別

顧客分群


K-means	Agglomerative Clustering	HDBSCAN
k=4, elbow method (最終採用👑)	k=4, 抽樣50000筆	min_cluster_size = 2000 min_samples = 100
k=6	k=6, 抽樣50000筆	☒ cluster number=5 ☒ silhouette score=0.16

顧客輪廓識別

編號	平均 Recency	平均 Frequency	平均 Monetary	行為輪廓	分群命名
0	③ 173.55	② 1.40	① 2859.10	中等活躍、高消費	穩定消費型
1	④ 392.58	④ 1.19	③ 738.26	不活躍、低消費	流失風險型
2	① 119.84	③ 1.31	④ 656.28	最近活躍、低消費	新進潛力型
3	② 122.59	① 3.98	② 2028.44	積極活躍、中高消費	高頻高價值型

PCA降維 視覺化分布

- 0 - 穩定消費型
- 1 - 流失風險型
- 2 - 新進潛力型
- 3 - 高頻高價值型



04

消費關鍵因子分析

分析方法簡介

1. 目標變數：實際消費金額、再購行為
2. 分析方法：線性迴歸（顯著變數） + XGBoost（重要特徵）
3. 再購定義：
 - a. 曾購一次以上（對應結果一）
 - b. 基準日前365天內回購（對應結果二）
 - c. 首購日起365天內回購（對應結果三）

再購定義比較

	特徵	情境
曾購一次以上	結構特徵 + 長期行為模式	顧客潛力探索、輪廓建立
基準日前365天	短期行為指標	即時行銷、忠誠顧客維護
首購後365天	初期互動特徵	新客培育、LTV 預測與導購優化

結果一：曾購一次以上

分群	金額關鍵因子	再購關鍵因子	建議策略
穩定消費型	線上註冊來源、Recency、會員等級（10~30與否）	會員等級（10~30與否）、線上註冊來源、App 安裝	推出 App 限定折扣與回購提醒，提升回購率並延續高客單價貢獻
流失風險型	Email 通知、線上註冊來源、會員等級（10~30與否）	Recency、線上註冊來源、App 安裝	強化多通路召回活動，結合精準推播、分眾內容與限時促銷
新進潛力型	會員等級（10~30與否）、Email 通知、線上註冊來源	Email 通知開啟、線上註冊來源、App 安裝	設計歡迎 EDM 與首購誘因，引導升級與持續互動
高頻高價值型	會員等級（10~30與否）、App 安裝、線上註冊來源	-	維繫忠誠顧客，整合 App 行銷與會員專屬獎勵方案，提升長期價值與留存率

結果二：基準日前365天

分群	金額關鍵因子	再購關鍵因子	建議策略
穩定消費型	最近一年購買次數、線上註冊來源、會員等級（10~30與否）	最近一年購買次數、線上註冊來源、會員等級（10~30與否）	推送定期回購提醒與會員回饋優惠
流失風險型	Email 通知、線上註冊來源、會員等級（10~30與否）	最近一年購買次數、Recency、線上註冊來源	推行喚醒型 EDM 與限時優惠
新進潛力型	最近一年購買次數、會員等級（10~30與否）、Email 通知	最近一年購買次數、Recency、Email 通知	設計首購推薦與會員升級誘因
高頻高價值型	會員等級（10~30與否）、最近一年購買次數、App 安裝	最近一年購買次數、Recency、簡訊通知	結合 App 與簡訊推送會員專屬活動

結果三：首購後365天

分群	金額關鍵因子	再購關鍵因子	建議策略
穩定消費型	購買頻率、線上註冊來源、會員等級（10~30與否）	購買頻率、會員等級（10~30與否）、線上註冊	推行限時優惠與會員回饋，刺激持續回購
流失風險型	Email 通知、線上註冊來源、會員等級（10~30與否）	購買頻率、Recency、會員等級（10~30與否）	利用 Email 設計回購循環行銷，拉長客戶生命週期
新進潛力型	購買頻率、會員等級（10~30與否）、Email 通知	購買頻率、會員等級（10~30與否）、Recency	建議導入「再購提醒」與「忠誠升等」誘因
高頻高價值型	會員等級（10~30與否）、購買頻率、App 安裝	購買頻率、Recency、會員等級（10~30與否）	結合 App 推播與會員專屬優惠，加強回購黏著度

05

再購機率預測與 LTV 模型建置

預測方法與評估指標

1. 目標變數：LTV（預測消費金額 × 再購機率）

2. 預測方法：XGBoost（迴歸與分類）

3. 評估指標

a. $\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$ ☒ 整體預測表現

B. R^2 ☒ 判斷模型解釋力

c. Error ratio ☒ 不同群之預測表現

預測結果

每群 LTV 預測統計：									
Cluster	Mean_True_LTV	Mean_Pred_LTV	RMSE	Error_Ratio (%)	Pred_Monetary	Pred_Reorder	True_Monetary	True_Reorder	
0	0.0	2125.68	1786.76	4713.67	221.75	2929.060059	0.62	3643.33	0.36
1	1.0	508.12	1.61	1574.60	309.89	1135.979980	0.00	941.00	0.31
2	2.0	639.70	351.93	1471.50	230.03	624.260010	0.56	960.71	0.40
3	3.0	969.47	0.00	1788.02	184.43	1989.810059	0.00	1192.55	0.57

▲曾購一次以上

每群 LTV 預測統計：									
Cluster	Mean_True_LTV	Mean_Pred_LTV	RMSE	Error_Ratio (%)	Pred_Monetary	Pred_Reorder	True_Monetary	True_Reorder	
0	0.0	2117.15	1301.069946	3781.12	178.59	3076.010010	0.36	3643.33	0.36
1	1.0	505.94	477.820007	1306.36	258.20	1258.229980	0.31	941.00	0.31
2	2.0	637.72	271.790009	1383.37	216.92	611.489990	0.40	960.71	0.40
3	3.0	968.48	1143.089966	1169.84	120.79	1936.189941	0.57	1192.55	0.57

▲基準日前365天

每群 LTV 預測統計：									
Cluster	Mean_True_LTV	Mean_Pred_LTV	RMSE	Error_Ratio (%)	Pred_Monetary	Pred_Reorder	True_Monetary	True_Reorder	
0	0.0	1134.69	690.679993	3288.38	289.80	3076.010010	0.18	3643.33	0.14
1	1.0	267.86	155.470001	1146.34	427.96	1258.229980	0.11	941.00	0.11
2	2.0	394.51	100.959999	1270.00	321.92	611.489990	0.20	960.71	0.18
3	3.0	701.32	1712.859985	1648.67	235.08	1936.189941	0.88	1192.55	0.32

▲首購後365天


比較分析

再購定義	預測誤差概況	特徵與預測傾向	模型評價
曾購一次以上	RMSE 偏高，誤差率達 184%~310%，群 1、3 預測幾近為 0	多數群體 LTV 被嚴重低估，特別是低頻顧客預測失準	無法辨識潛在回購顧客，預測失準，不適合實務應用
基準日前365天	RMSE 整體下降，誤差率介於 120%~258%	群 0、2 預測偏低，僅群 3 預測略高，預測再購率貼近實值	整體表現最佳，適合即時預測與應用
首購後365天	RMSE 偏高，誤差率達 235%~427%，群 1、2 明顯失準	多數群體 LTV 偏低，僅群 3 明顯高估（預測值超過實際 2 倍以上）	適合觀察新客潛力，但預測穩定性差，應搭配其他模型輔助應用


模型預測結果視覺化

基準日前 365 天

模型預測 LTV 與實際 LTV 的對應關係



各群體模型預測誤差 (Residual) 分析圖



06

總結與討論

總結



01

回購定義影響模型表現，基準日前 365 天最為平衡

比較三種回購定義下的模型表現，發現「近一年回購」在樣本穩定性與預測誤差間取得相對平衡。

02

模型整體偏保守

多數群體 LTV 被低估，可能受限於樣本中高價值顧客比例偏低、金額分布不均與特徵辨識力不足等因素。

03

高誤差集中於低頻或新客，特徵學習仍有不足

模型對低頻與新進顧客預測誤差大，誤差率常超過 300%，突顯資料稀疏下的學習限制。

討論與反思

1. 微幅誤差乘積效應，放大 LTV 預測偏差

由於定義 LTV 為金額 $\times$ 再購率，任何一方小幅失準都會造成整體預測放大效應，模型敏感度需進一步調整。

2. 單一再購定義難以同時適用於全客層

不同分群顧客的行為差異大，模型對低頻（如群 1）與新進顧客預測誤差高，未來可考慮採用群別專屬模型或分層建模策略。

A large, light blue, abstract, organic shape with irregular, wavy edges. It is centered on a white background. The shape has a soft, painterly quality, with some areas appearing slightly more saturated than others, giving it a sense of depth and movement. It resembles a splash or a cloud.

THANK YOU