



基於文本的股價漲跌分類與預測模型分析

113-2 大數據與商業分析 期中報告

經濟四	王乙軒、闕蕎蓁、姚力瑋
圖資碩二	蔡馨頤
生醫電資碩二	王仁宏
財金三	鄭凱元

APRIL 23, 2025

報告大綱



01

選股邏輯

02

資料
前處理

03

分類模型

04

移動回測

05

反思與結論

01

選股邏輯

世芯-KY (3361)

公司介紹

世芯-KY 為一間專注於 ASIC（客製化晶片）設計服務的半導體公司。其主要客戶涵蓋 AI、高速運算、資料中心等領域，以台灣與北美市場為主。近年受惠於 AI 應用成長與晶片客製化需求增加，已成為全球具代表性的 ASIC 設計服務廠商。

交易資訊

- 股價：2680
- 股本：7.92億
- 股淨比：6.36
- 本溢比：53.25

選股原因一：聲量高，討論度足

- 2023.1~2025.3 總文章數高達5230篇

選股原因二：股價波動明顯

- 2023~2025 股價有明顯波動，漲跌幅超過300%

世芯-KY (3661)

資料時間：2025/04/16

2022/12/30 開 952 高 960 低 731 收 788 量(張) 97446 漲跌 -139

MA5 817.6 ▲ MA20 847.15 ▲ MA60 466.91 ▲



02

資料前處理

漲跌標記



方法一：以「市場反應」進行標記

- 以文章發布日後第三天的股價漲跌幅作為預測目標，將漲跌幅超過 $\pm 3\%$ 的文章標記為「看漲」與「看跌」，其餘則標記為「持平」。
- 看漲文章：1849 篇
- 看跌文章：1225 篇
- 持平文章：2127 篇
- 未標記：29 篇

方法二：以「文本內容」進行標記

- 利用大型語言模型（LLM）Llama-3.1-8B 進行 zero-shot 標記。模型無需經過微調，即可根據語意推理能力對每篇文章判斷其立場為「看漲」、「看跌」或「持平」。
- 看漲文章：3469 篇
- 看跌文章：1461 篇
- 持平文章：300 篇



斷詞處理

中文斷詞處理 — Monpa 工具



e.g. 「的」、「是」、「了」、「我」、「他」

關鍵字篩選（手動）

雜訊過濾規則

 過短字詞
e.g. 長度 $\leq$ 1

 URL 片段
e.g. abc.com

 過長混合詞
e.g. a123zz/api

 純數字
e.g. 123

 時間 / 日期格式
e.g. 23/04/16

 黑名單詞彙
e.g. 任務自訂

關鍵字篩選（手動）



TF-IDF 計算（手動）

- 篩選每組（如看漲/看跌）前 `top_n` 高分詞（`top_n=1000`）

選出具區辨性的關鍵詞（1292 terms）

- 將上漲組與下跌組的 TF-IDF 合併比對
- 計算每個詞的 TF-IDF 差異：
- `tfidf_diff = tfidf_score_up - tfidf_score_down`
- 各取差異最大（正值與負值）的前半詞彙，合併成「選定字彙表（vocab）」儲存

```
Vocabulary selected and saved to selected_keywords_tfidf_merge.csv, containing 1292 terms
A total of 4535 articles processed
TF-IDF sparse matrix saved to vector space tfidf_merge.npz, with shape (4535, 1292)
```

關鍵字篩選 (套件)



直接使用套件計算 TF-IDF (44316 terms)

- `TfidfVectorizer()`
- 保留語料全部資訊
- 模型有機會自動學出重要詞

```
sparse matrix: <Compressed Sparse Row sparse matrix of dtype 'float64'
with 933795 stored elements and shape (4535, 44316)>
Coords      Values
(0, 3254)    0.04293724267657242
(0, 14593)   0.04677378403020844
(0, 18835)   0.09905298154151666
(0, 17574)   0.03304700278705654
(0, 25605)   0.18299692480140545
(0, 1265)    0.07229301335736064
(0, 563)     0.07656642562392481
(0, 1805)    0.0671222285213568
(0, 29391)   0.05636781645351135
(0, 18804)   0.040514132143713986
(0, 4123)    0.029421441355034213
(0, 6773)    0.09814563666616899
```

向量化處理



手動方法

- `TfidfVectorizer(vocabulary=vocab, lowercase=False)`
- 載入手動處理後的選定字彙表 `vocab`

套件方法

- `vectorizer = TfidfVectorizer()`
 - `X = vectorizer.fit_transform(df['content_str'])`
 - 直接透過套件將斷詞後結果全部進行向量化處理
-

03

分類模型

分類模型



- 使用資料（共 2 種）
 - 標記方式 A：以「市場反應」進行標記
 - 標記方式 B：以「文本內容」進行標記（LLM）
- 向量轉換方法（共 2 種）
 - 方法 A：使用關鍵字字典建立 TF-IDF 向量空間
 - 方法 B：對所有斷詞後文本，不限制詞彙使用 TfidfVectorizer() 向量化
- 資料切分：經標記之看漲看跌文章經向量處理後，皆切分為80%訓練集、20%測試集
- 使用模型（共 8 種）
 - Naïve Bayes, SVM(rbf/linear), KNN, Decision Tree
 - Random Forest, MLP Neural Net, XGBoost, KERA
- 組合數量：2（資料標記方式） × 2（向量化方式） × 8（模型），共 32 種模型進行訓練
- 評估指標：Accuracy, Confusion Matrix, Precision, Recall, F1-Score

分類模型——「市場反應」標記

Accuracy (%)

Accuracy (%)	Naïve Bayes	SVM	KNN	Decision Tree	Random Forest	MLP Neural Net	XGBoost	KERA
關鍵字	65	67	66	62	68	66	66	66
全字詞	62	74	63	61	70	76	68	75

分類模型——「LLM」標記


關鍵字	70	72	67	61	71	65	69	65
全字詞	79	91	85	81	85	91	89	92

分類模型 —— 「LLM」 標記 + 直接取向量

看跌標記為 0 ； 看漲標記為1


- 最終為LLM標記之資料集 + 直接取向量之方法表現最佳。
- 其中，KERA、MLP Neural Net、SVM(linear)為表現前三名，且準確度都高於90%

KERA




- Precision : 92% (91%/92%)
- Recall : 92% (80%/97%)
- f1-score : 92% (85%/94%)

MLP NEURAL NET



- Precision : 91% (92%/91%)
- Recall : 91% (76%/97%)
- f1-score : 91% (83%/94%)

SVM (LINEAR)



- Precision : 91% (91%/91%)
- Recall : 91% (78%/97%)
- f1-score : 91% (84%/94%)

04

移動回測

移動回測



每次以前一個月之文章訓練，並依當日文章預測股價漲跌，以當日實際股價漲跌判斷分類對錯

選用模型：SVM Linear kernel

對於測試集，有兩種建立方式：當日所有文章合併後判斷漲跌、個別文章漲跌機率加權

出手標準：判斷值小於0.33（跌）或大於0.66（漲）



當日所有文章合併後判斷漲跌


將當日所有文章的斷詞合併為一段後轉為TF-IDF向量

出手日數：407 / 485（83.92%）

Accuracy：60.69%

Precision：漲58.54%、跌76.00%

Recall：漲94.57%、跌20.43%



移動回測



個別文章漲跌機率加權

將當日每篇文章的斷詞各自轉為TF-IDF向量後判斷漲跌機率，並將所有機率加總取平均

出手日數：317 / 485 （65.36%）


Accuracy：61.51%

Precision：漲60.20%、跌78.26%

Recall：漲97.25%、跌13.33%

其他嘗試：對樣本較少的下跌文章進行Oversampling、以下一交易日之股價判斷分類對錯
結果：成效不佳，後者可能表示市場對於新聞能夠即時反應

不論採用何種方式回測，在多數交易日皆判斷為漲，導致下跌的Recall很低。




移動回測



個別文章漲跌機率加權方法
下，每個月出手的準確率

準確率低的原因，可能是文章
內容混雜「新資訊」與「當日
交易動態」（即已反映在股價
上之資訊），對預測較為不利



05

反思&結論

討論



研究發現一：「文本內容」標記優於「市場反應」標記

市場反應標記



優點：

- 具備量化標準與客觀性，可直接使用股價資料進行自動標記。

限制：

- 容易受市場其他訊息干擾（例如大盤波動、非本文事件），導致與文章本身內容無關的誤標。

文本內容標記法



優點：

- 能準確捕捉文章本身所傳達的情緒與立場，具有一致性與可重現性。
- 結果顯示模型更能從這種標籤中學習到與語意真正相關的特徵，預測效果更佳。

討論



研究發現二：使用「所有詞彙」建構向量空間優於僅使用「關鍵字」

特徵選取方式	所有詞彙（全特徵）	關鍵字（篩選後詞彙）
資訊完整度	✓ 高	✗ 遺漏
模型表現	✓ 較佳	↓ 稍低
可解釋性	↓ 較低	✓ 較高

THANK YOU

說明影片

<https://youtu.be/jUzusKt7mA>