

透過數據分析進行工廠用電與太陽能發電排程最佳化

陳詠平¹ 唐珩鈞² 林詔均³ 關蕎蓁⁴

¹ 國立臺灣大學生物產業傳播暨發展學系, B11610016

² 國立臺灣大學法律學系, B12A01343

³ 國立臺灣大學政治學系, B11302158

⁴ 國立臺灣大學經濟學系, B10303125

1 研究背景與動機

近年隨著綠能產業發展，工廠興建太陽能板之比例逐漸升高，企業降低其用電成本之方式不再是純粹降低總用電量，其如何調度儲電系統之充放電更是影響購電成本之重大因素，因此本研究希望透過資料科學方法有效預測企業用電量與太陽能發電量，並結合數學最佳化模型安排儲能系統之充放電策略，以降低企業在時間電價制度下的電力成本與超約風險。本研究以下列三點為核心主軸：

- 建立用電量預測模型，預測企業未來用電需求，以作為能源調度之依據。
- 建立太陽能發電預測模型，透過氣象與歷史發電資料提升發電量預測能力。
- 建立儲能系統最佳化調度模型，在時間電價與契約容量限制下，決定最佳充放電策略，以降低企業購電成本與尖峰需求。

2 研究方法

本研究採用「預測—最佳化」兩階段架構，先以機器學習方法建立工廠用電量與太陽能發電量之短期預測模型，再將預測結果作為混合整數線性規劃模型之輸入，求解儲能系統之最佳充放電排程。此架構常見於能源管理系統相關研究，其核心優勢在於將「需求與供給不確定性的量化」與「能源資源調度」兩項問題解耦，使預測模型與最佳化模型能分別採用最適切的方法工具。

2.1 研究流程設計

本研究流程分為五個階段。第一階段為資料蒐集與前處理，蒐集鋼鐵廠歷史用電資料，以及太陽能電廠之氣象與發電資料，並針對缺失值、異常值、類別變數編碼、時間電價時段對應等項目進行系統性清理。第二與第三階段分別建立用電量與發電量之預測模型，皆採用 XGBoost 梯度提升決策樹演算法，並透過貝氏最佳化進行超參數調整。第四階段建立分層式 MILP 最佳化模型，包含長期日前排程與短期即時調度兩個層級。第五階段為模型評估與經濟效益分析，透過與五種傳統規則式策略之對比，量化本架構在電費節省、削峰填谷與超約風險控制方面之表現。

2.2 預測模型方法論

預測模型的選擇基於資料特性與部署需求兩項考量。在資料特性上，電力負載與太陽能發電皆呈現顯著的非線性關係；例如雲量、輻射與溫度對發電量的影響存在閾值效應，而工廠負載則受到作息、設備啓停與電力品質（如無效功率）等因素交互影響。樹模型適合處理此類具有非線性閾值結構與高維特徵交互的表格資料，因此本研究採用 XGBoost 作為主要預測模型。在部署需求上，本研究亦重

視模型可解釋性，以利下游最佳化決策與後續參數調校；XGBoost 可搭配 SHAP 解釋框架，分解各特徵對個別預測結果之貢獻，符合本研究之應用需求。

為避免時序資料洩漏，本研究在資料切分上採用時間序列分割而非隨機分割，確保訓練集嚴格早於驗證集與測試集；在交叉驗證上則採用擴展視窗法，逐步推進訓練範圍以模擬實務部署情境。此外，所有滯後特徵與滾動統計特徵在計算時皆透過 shift 處理，確保模型僅引用當下時間點之前的資料。

針對不確定性量化，本研究除建立點預測模型外，另訓練分位數迴歸模型作為風險評估之輔助輸入。用電量方面建立 90% 分位數上界，作為估計超約風險之保守邊界；發電量方面建立 10% 分位數下界，作為儲能排程的保守輸入。分位數迴歸使預測結果不再侷限於條件期望值，而能提供不確定性區間估計，為下游最佳化模型之穩健決策提供量化依據。

在超參數調整方法的選擇上，本研究採用 Bayesian Optimization 而非 Grid Search 或 Random Search。Grid Search 透過窮舉所有參數組合進行搜尋，在搜尋空間維度較高時計算成本急遽上升；Random Search 雖能緩解此問題，但其搜尋過程無方向性，未利用既有評估結果指引下一步。Bayesian Optimization 透過代理模型（通常採用高斯過程或樹結構 Parzen 估計器）建模目標函數，每次迭代依據歷史評估結果推估下一最有潛力的參數組合，在相同迭代次數下通常能找到優於前兩者的超參數組合。考量本研究 XGBoost 模型之超參數空間具有連續性與多維度交互作用，採用 Bayesian Optimization 較能在有限計算預算下找到接近全域最佳的設定。

2.3 最佳化模型方法論

儲能系統之充放電排程同時涉及長期規劃需求與短期即時波動，因此本研究採用分層式能源管理架構。此架構之核心理念為將決策時間尺度解耦：長期排程負責規劃次日的 SOC 基準軌跡與尖峰預備容量，短期調度則依據即時更新之預測結果動態修正充放電決策。

在最佳化架構上，本研究採用分層式設計而非單一時間尺度的 MILP，基於以下考量。單層 MILP 若採用高解析度（如 15 分鐘）並涵蓋長時間視窗（如整日 24 小時），決策變數規模急遽膨脹，求解效率顯著下降；若採用低解析度（如 1 小時），則無法捕捉短期負載與發電的快速變化，調度精度不足。分層式架構將此兩難解耦：長期排程以 1 小時解析度規劃次日 SOC 軌跡，提供策略性方向；短期調度以 15 分鐘解析度修正即時偏差，提供戰術性精度。此設計亦符合電網調度領域常見的「滾動式模型預測控制」框架，能在預測誤差累積前持續修正決策。

本研究之目標函數涵蓋多項成本與懲罰項，包含購電電費、當日最高需量懲罰、契約容量超約罰款、SOC 基準線追蹤偏離、月最高需量懲罰、電池壽命衰退成本、再生能源棄光懲罰，以及上午安全 SOC 軟性約束。各項權重依據本研究資料尺度與情境設定校準，使模型能在降低電費、控制超約風險與維持電池運作穩定性之間取得平衡。

2.4 評估與比較框架

模型評估採用三層次指標。第一層為預測模型本身之準確度指標，包含 MAPE、MAE 與 RMSE；針對太陽能發電資料，本研究另納入限定於日照時段的條件式 MAPE，以避免夜間零值或低發電量時段對指標造成扭曲。第二層為分位數模型之校準指標，用以檢驗實際值落於預測區間之比例是否符合理論目標。第

三層為最佳化排程之經濟效益指標，包含月總電費、超約罰款、峰谷比、再生能源利用率與電池等效循環次數，並透過與五種規則式基準策略之對比，量化本架構之相對效益。

3 用電量預測分析

3.1 資料收集

本研究所使用之用電量資料取自 Kaggle 開放資料集「Steel Industry Energy Consumption」。該資料集包含鋼鐵製造廠 365 天、每 15 分鐘一次的耗能數據。主要特徵包含連續型變數（如：總用電量、領先與落後無效電力等）以及時間與負載類型等類別型變數。在資料前處理階段，首將時間欄位轉換為標準 DateTime 格式並設定為索引以利時序分析。本研究亦針對原始時序數據執行四項特徵工程：

- **時間週期編碼**：將月份與小時進行正弦與餘弦轉換，賦予時序特徵連續性，以利模型捕捉長短期規律。
- **電價標籤與作息特徵**：區分平假日並對星期進行獨熱編碼；另依台電時間電價制度標記各資料點之計費時段，以銜接下游最佳化排程。
- **時序滯後與動能**：建立滯後 1、2、4 與 96 期之用電量變數，並取 1、2 期差值作為短期動能特徵，同步納入無效電力之滯後項。
- **滾動統計與共線性篩選**：計算過去 1 小時移動平均與 2 小時標準差以反映負載波動；訓練前剔除相關係數大於 0.90 之變數，防範模型過擬合。

3.2 分析

本節基於前述 3.1 節所建置之完整特徵空間，建置 XGBoost 預測模型，並透過 optuna 框架進行超參數最佳化尋優。

鑑於原始用電量數據呈現右偏的分佈特性，本研究於訓練階段對目標變數進行對數轉換，並於預測階段進行反對數還原。此轉換有效穩定變異數，減輕極端離群值對模型梯度更新之干擾。此外，模型驗證採用時間序列交叉驗證法，以擴展視窗方式依序推進訓練集，嚴格維持時間序列之單向性，杜絕資料洩漏疑慮。

基於上述架構，本研究於測試集同步產出兩組具備相異統計性質之模型結果：

- **主預測模型**：藉由最小化均方誤差，使其預測值收斂於給定特徵下之條件期望值，用以提供基準之平均用電負載預測。
- **防護模型**：藉由最小化分位數損失，使其預測值收斂於第 90 百分位數，作為評估極端負載波動之風險緩衝基準。

另外，本模型使用 Python 3.11 實作，主要套件包含 xgboost (v2.0)、optuna (v3.5)、shap、pvlib（僅發電模型）。模型訓練於本機 CPU 環境完成。

3.3 解釋

本研究採用四折時間序列交叉驗證評估預測模型，並比較基準線模型、XGBoost 預設參數模型，以及經貝氏最佳化調校後之模型表現。評估指標除相對誤差外，亦納入 MAE 與 RMSE 等絕對誤差指標，以量化模型在實際用電預測上的表現，結果如表 1 所示。

評估表 1 之量化結果，導入 XGBoost 預設參數模型後，相較單純採用滯後一期的基準線模型獲得明顯改善，確立機器學習演算法於此資料集之應用價值。

Table 1: 用電量預測模型之效能與消融實驗結果比較

評估指標	基準線模型	XGBoost (預設參數)	XGBoost (貝氏最佳化)
MAPE (%)	22.98	16.47	15.00
MAE (kWh)	5.85	4.67	4.34
RMSE (kWh)	13.10	9.83	9.26

在確認模型演算法之可行性後，本研究進一步透過 optuna 框架執行貝氏最佳化以進行超參數調校。量化數據顯示，最佳化後的 XGBoost 模型平均 MAPE 收斂至 15.00%，特別在反映預測極端失準程度的 RMSE 指標上，其數值由 9.83 kWh 下降至 9.26 kWh。此 RMSE 的收斂，說明模型在面對突發性高負載情境時的預測穩定度有所提升，有助於降低後續即時調度之決策風險。針對用電不確定性，本節所建置之 90% 分位數迴歸模型於測試集上測得 90.88% 的平均分位數覆蓋率。此一結果與預期之統計機率分佈相符，意即實際用電量突破該預測上界之機率被有效控制於 10% 以內。在實務應用層面，將此機率性預測生成之高標數值，作為後續能源管理系統最佳化調度之輸入參數，可直接用於估算超約懲罰之期望成本，為充放電排程提供客觀的量化風險評估依據。

進一步而言，XGBoost 點預測結果與 q90 分位數預測可分別作為下游最佳化模型（第 5 節）的兩類輸入：前者代表「最可能負載」估計，用以提供主要的成本最小化方向；後者則代表「保守上界」，可用於估算超約懲罰之期望成本，使最佳化目標函數同時納入一般情境與高負載風險情境之成本權衡。透過此雙輸入設計，充放電排程不僅能追求成本最小化，也能提升面對預測誤差時的穩健性。

綜合分析模型在不同情境下的表現特徵，可發現用電模型對「跨日重複性高的固定負載」（如夜間基礎負載、週末停機）預測表現極佳，但對「設備啟動瞬間的尖峰」較難精確預測。此一發現與工廠用電的物理特性一致——設備啓停的決定權在於現場排程，難以僅憑歷史資料推測。對 EMS 而言，這項洞察意味著：分位數模型在處理「可預期負載」時提供精準預測，但在「突發負載」時其價值更多在於提供風險邊界，而非精確預測值。

4 發電量預測分析

4.1 資料收集

本研究使用之用電量資料取自 Kaggle 開放資料集「Renewable Power Generation and weather Conditions」，自 2017 年 1 月至 2022 年 8 月的營運紀錄。資料時間粒度為每 15 分鐘一筆。主要欄位包含每 15 分鐘區間內的實際發電量、氣象觀測資料、輻射相關變數以及時間戳記與日照標記。

資料前處理首先檢查時間序列之完整性，確認資料無時間跳空，並將時間欄位轉換為標準日期時間格式以利後續時序建模。由於 GHI 等輻射欄位在夜間可能出現微量負值，此類數值屬於低光環境下的感測器雜訊，故依物理意義將其截斷為零。離群值檢查顯示，高發電極端值多集中於夏季正午晴天，屬於真實物理現象，因此未予刪除。

4.2 分析

本節建立以氣象特徵為輸入、預測每小時太陽能發電量之機器學習模型。為避免資料洩漏，本研究未將同一時間點的實測 GHI 與 `clear_sky_index` 直接作為主模型特徵，而是採用 `forecast-strict` 特徵集，僅保留實務上可由天氣預報或歷史資料取得之變數，例如溫度、濕度、壓力、風速、雲覆蓋率，以及歷史發電與輻射的滯後特徵與滾動統計量。

特徵工程主要包含四類。第一，建立滯後特徵，前 1 小時、前 3 小時與前 24 小時之發電量與輻射資訊，以捕捉短期天氣持續性。第二，建立過去 3 小時平均與標準差等滾動統計量，用以反映雲層快速變化造成的短期波動。第三，將小時與月份轉換為 `sin/cos` 循環編碼，避免模型將 23 點與 0 點視為距離很遠的狀態。第四，利用天文計算取得太陽仰角、方位角與理論晴空輻射等物理確定性特徵，作為模型判斷發電上限的參考。

模型部分採用 XGBoost 作為主預測器，並以貝氏最佳化進行超參數調整。資料切分採時間序列切分，測試集為時間序列最後 20%，前段資料再切出驗證集進行模型比較與調參。交叉驗證時並確保每一折訓練資料皆早於驗證資料，避免時序資料洩漏。除點預測模型外，本研究亦訓練 XGBoost Quantile Regression 作為 10% 分位數下界模型，以提供下游儲能最佳化較保守的發電量估計。

4.3 解釋

由表 2 可見，單純以前一日同時段發電量作為預測的 Persistence 基準線表現較弱，顯示相鄰兩日的雲層與日照條件可能有顯著差異。線性迴歸模型已可捕捉部分氣象特徵訊號，而 XGBoost 進一步透過樹模型結構掌握雲量、日照與發電量之間的非線性關係。經貝氏最佳化調參後，XGBoost 在測試集上取得最佳表現。

Table 2: 太陽能發電量預測模型比較

模型	驗證集 MAPE	測試集 MAPE	測試集 R^2	測試集 RMSE
Persistence (前日同時段)	123.62%	94.51%	0.3299	990.22 Wh
線性迴歸模型	65.65%	59.23%	0.8124	523.86 Wh
XGBoost (預設參數)	41.71%	39.26%	0.8501	468.34 Wh
XGBoost (貝氏最佳化調參)	38.75%	36.10%	0.8599	452.82 Wh

為檢驗不確定性估計，本研究進一步評估 10% 分位數模型。該模型的目標並非預測平均發電量，而是提供保守下界，使實際發電量在大多數情況下高於此預測值。結果顯示，q10 模型於日照時段之實際覆蓋率為 89.07%，與理論目標 90% 僅相差不到 1 個百分點，表示模型校準良好。

誤差結構分析顯示，整體 MAPE 偏高主要來自低發電時段的分母效應。在高發電區間（2000–5000 Wh）中，模型 MAPE 僅為 14.68%，Median APE 為 9.61%，代表模型在對儲能排程較具決策價值的高發電時段表現相對穩健。另一方面，高誤差樣本多發生於雲量高、近期 GHI 變異大，但前期發電量仍偏高的情境，顯示模型較容易在雲層快速變化時高估發電量。

此一誤差模式反映了一個關鍵的物理事實：模型能準確學習「穩定天氣下的太陽能發電」，但無法預測「天氣轉變的時點」。這也指出未來改進方向——若能整合更高時間解析度的雲層動態資料（例如衛星雲圖、雷達回波），或許能在轉換型天氣下進一步降低誤差。然而，從決策角度而言，q10 分位數的存在使得排程

Table 3: Quantile 下界模型校準結果

指標	數值
目標覆蓋率	90%
實際覆蓋率	89.07%
q10 平均偏離實際值	-444 Wh
q10 與點預測平均間距	451 Wh

不需依賴模型「預測天氣轉變」的能力，而是在數學上將此不確定性納入決策邊界，這正是本研究設計分位數模型的核心動機。

5 充放電排程最佳化分析

本研究採用雙層式能源管理架構，包含長期每日排程與短期即時調度。系統會每 15 分鐘重新執行一次最佳化，並根據未來預測區間內的用電量與太陽能發電量結果，動態調整儲能系統充放電之策略。

5.1 最佳化設定

為有效進行預測及比較，本研究針對各項參數進行假設（如下表）：

Table 4: 參數設定

符號	數值	說明
Q	2000 kWh	電池電能容量
η_{ch}	0.95	充電效率
η_{dis}	0.95	放電效率
$P_{max,ch}^{ST}$	800 kW	短期最大充電功率
$P_{max,dis}^{ST}$	1000 kW	短期最大放電功率
$P_{max,ch}^{LT}$	120 kW	長期最大充電功率
$P_{max,dis}^{LT}$	150 kW	長期最大放電功率
SOC_{min}	0.20	電量狀態 (SOC) 下限
SOC_{max}	0.90	電量狀態 (SOC) 上限
SOC_{target}	0.40	終端 SOC 目標值
$\bar{P}_{contract}$	400 kW	台電經常尖峰契約容量
$\bar{P}_{contract}$	18	太陽能發電量倍數

- **SOC 上下限**：剩餘電量上下限是為了保護電池壽命、防止安全危險並維持輸出穩定。
- **契約容量**：契約容量是指同時運轉的設備所需的最大功率，而工廠會與台電簽約一定電量，一旦超過上限，就會面臨超約罰款。本研究設置為一般中大型工廠的容量 400 kW。
- **電池容量**：為了確保有足夠容量能讓設備運行，參考資料集中工廠日平均用量 (2,725 kWh)，故假設工廠儲能設備電池容量為 2,000 kWh。

- **太陽能發電量倍數**：為平衡用電與發電量資料集尺度，以鋼鐵工廠年用量 994,625 kWh 評估，以年用電密度約 750 kWh/m² 計算，應有約 1,326 m² 之佔地面積。評估不會所有地方都鋪設太陽能板，因此最終假設鋪設 1,300 m² 面積之太陽能板。再假設每日發電量 0.75 kWh/m²，則最終每日平均發電量應為 975 kWh。考量訓練資料集平均日發電量為 54 kWh，因此設定太陽能發電量倍數為 18，以平衡用電與發電量。

5.2 短期 MILP（每 15 分鐘排程規劃）

短期最佳化之目標為在未來 6 小時（共 24 個 15 分鐘時段）內，最小化系統整體運行成本。成本內容包含購電成本、基本電費估算項、契約容量超約罰款，以及 SOC 與長期規劃目標之偏差等成本，其目標函數可表示如下。

其中， $\bar{C}$ 為該時間視窗內的平均電價， $\sigma(t)$ 為捕捉充放電模式切換幅度的鬆弛變數， ξ_τ 用於懲罰上午 09:00 前低於目標值的 SOC，而 $P_{\text{mth}}(t)$ 則針對超過當月累積最高需量的部分進行懲罰。

$$\begin{aligned}
\min \quad & \underbrace{\sum_{t=1}^T P_{\text{grid}}(t) C_{\text{price}}(t) \Delta t}_{\text{購電電費}} + \underbrace{\lambda_{\text{peak}} \bar{P}_{\text{day}}}_{\text{當日最高需量懲罰}} \\
& + \underbrace{\lambda_{\text{exc}} \sum_{t=1}^T P_{\text{exc}}(t)}_{\text{超約契約容量罰款}} + \underbrace{w_{\text{soc}} s_{\text{dev}}}_{\text{SOC 基準線追蹤懲罰}} + \underbrace{\lambda_{\text{monthly}} \sum_{t=1}^T P_{\text{mth}}(t)}_{\text{月最高需量懲罰}} \\
& + \underbrace{\lambda_{\text{deg}} \sum_{t=1}^T (P_{\text{ch}}(t) + P_{\text{dis}}(t)) \Delta t}_{\text{電池壽命衰退成本}} + \underbrace{\lambda_{\text{curt}} \sum_{t=1}^T P_{\text{curt}}(t) \Delta t}_{\text{再生能源棄光懲罰}} \\
& + \underbrace{\lambda_{\text{store}} \sum_{t=1}^T P_{\text{dis}}(t) \bar{C} \Delta t}_{\text{儲存電能使用成本}} + \underbrace{\lambda_{\text{switch}} \sum_{t=1}^T \sigma(t)}_{\text{充放電模式切換懲罰}} + \underbrace{\lambda_{\text{morning}} \sum_{\tau \in \mathcal{T}_{\text{am}}} \xi_\tau}_{\text{上午安全 SOC 懲罰}}
\end{aligned} \tag{1}$$

1. 功率平衡限制

$$P_{\text{load}}(t) = P_{\text{pv}}(t) - P_{\text{curt}}(t) + P_{\text{grid}}(t) + P_{\text{dis}}(t) - P_{\text{ch}}(t), \quad \forall t \tag{2}$$

其中 $P_{\text{load}}(t)$ 與 $P_{\text{pv}}(t)$ 分別為來自 XGBoost 負載模型與太陽能發電模型的預測資料。

2. SOC 動態特性

$$\text{SOC}(t+1) = \text{SOC}(t) + \frac{\eta_{\text{ch}} P_{\text{ch}}(t) \Delta t}{Q} - \frac{P_{\text{dis}}(t) \Delta t}{\eta_{\text{dis}} Q}, \quad \forall t \tag{3}$$

3. SOC 上下限約束

$$\text{SOC}_{\min} \leq \text{SOC}(t) \leq \text{SOC}_{\max}, \quad \forall t \quad (4)$$

4. 充放電功率限制

$$0 \leq P_{\text{ch}}(t) \leq P_{\max, \text{ch}}, \quad \forall t \quad (5)$$

$$0 \leq P_{\text{dis}}(t) \leq P_{\max, \text{dis}}, \quad \forall t \quad (6)$$

5. 互斥約束（禁止同時充放電）

$$P_{\text{ch}}(t) \leq u(t) P_{\max, \text{ch}}, \quad \forall t \quad (7)$$

$$P_{\text{dis}}(t) \leq (1 - u(t)) P_{\max, \text{dis}}, \quad \forall t \quad (8)$$

$$u(t) \in \{0, 1\}, \quad \forall t \quad (9)$$

6. 超約容量判定

$$P_{\text{exc}}(t) \geq P_{\text{grid}}(t) - \bar{P}_{\text{contract}}(t), \quad \forall t \quad (10)$$

$$P_{\text{grid}}(t) \leq \bar{P}_{\text{contract}}(t) + P_{\text{exc}}(t), \quad \forall t \quad (11)$$

其中 $\bar{P}_{\text{contract}}(t)$ 為依據台電電價表變化的可用契約容量。

7. 當日最高需量追蹤

$$\bar{P}_{\text{day}} \geq P_{\text{grid}}(t), \quad \forall t; \quad \bar{P}_{\text{day}} \geq P_{\text{day, so far}} \quad (12)$$

8. 終端 SOC 追蹤

$$s_{\text{dev}} \geq \text{SOC}(T) - \text{SOC}_{\text{ref}}(T) \quad (13)$$

$$s_{\text{dev}} \geq \text{SOC}_{\text{ref}}(T) - \text{SOC}(T) \quad (14)$$

其中 SOC_{ref} 是自長期排程而得之每小時基準（參見第 5.3 節）。

9. 上午 SOC 軟性約束（09:00 之前）

$$\xi_{\tau} \geq \text{SOC}_{\text{am}}^* - \text{SOC}(\tau), \quad \forall \tau \in \mathcal{T}_{\text{am}} \quad (15)$$

其中 $\text{SOC}_{\text{am}}^* = 0.75$ （夏月）或 0.60 （非夏月）， $\mathcal{T}_{\text{am}}$ 代表 09:00 之前的所有時間步。

10. 時間電價充電策略限制

$$P_{\text{ch, grid}}(t) \leq \bar{P}_{\text{ch, grid}}^{\text{TOU}}(t), \quad \forall t \quad (16)$$

$$P_{\text{ch, pv}}(t) \leq \max(0, P_{\text{pv}}(t) - P_{\text{load}}(t)), \quad \forall t \quad (17)$$

其中 $\bar{P}_{\text{ch, grid}}^{\text{TOU}}(t)$ 在尖峰時段設定為 0；在離峰時段等於 $P_{\max, \text{ch}}$ ；在半尖峰時段，若預測未來存在尖峰需量風險，則會條件式放寬允許充電。

5.3 長期 MILP（每日排程規劃）

長期排程器每日執行一次，以 1 小時為時間解析度，針對未來 24 小時建立 MILP 最佳化模型（即 $T = 24$ 、 $\Delta t = 1$ hour），並產生作為短期調度參考之 SOC 基準軌跡 $\text{SOC}_{\text{ref}}(\cdot)$ ：

$$\begin{aligned} \min \quad & \sum_{t=1}^{24} P_{\text{grid}}(t) C_{\text{price}}(t) \cdot 1 \\ & + \alpha_{\text{bat}} \sum_{t=1}^{24} (P_{\text{ch}}(t) + P_{\text{dis}}(t)) \\ & + \lambda_{\text{exc}}^{\text{LT}} \sum_{t=1}^{24} P_{\text{exc}}(t) + C_{\text{basic,daily}} + C_{\text{morning}} \end{aligned} \quad (18)$$

其中 $\alpha_{\text{bat}} = \lambda_{\text{deg}}$ 為壽命衰退成本權重， $C_{\text{basic,daily}}$ 為按日分攤的基本電費。長期與短期模型限制條件大致相同，唯時間尺度有差異：

$$\text{SOC}(t+1) = \text{SOC}(t) + \frac{\eta_{\text{ch}} P_{\text{ch}}(t) \cdot 1}{Q} - \frac{P_{\text{dis}}(t) \cdot 1}{\eta_{\text{dis}} Q}, \quad t = 1, \dots, 24 \quad (19)$$

$$\text{SOC}(24) \geq \text{SOC}_{\text{target}} \quad (20)$$

短期調度使用之 SOC 參考基準，結合了 MILP 所產生之 SOC 基準 SOC^{MILP} 與基於時間電價規則建立之 SOC 基準 SOC^{TOU} ：

$$\text{SOC}_{\text{ref}}(t) = (1 - w_{\text{TOU}}) \text{SOC}^{\text{MILP}}(t) + w_{\text{TOU}} \text{SOC}^{\text{TOU}}(t), \quad w_{\text{TOU}} = 0.65 \quad (21)$$

5.4 數值模擬結果

圖 1 為系統模擬從預測到最佳化後的排程圖，以 7 月 13 日為例，可以發現在尖峰時段（16:00–22:00）購電量顯著降低，且儲能系統開始大量放電，使 SOC 從高峰降至低峰，達成將太陽能發電效益延後至電價高峰時段使用的效果。




Figure 1: 2018 年 7 月 13 日儲能系統最佳化排程結果

2018 年 7 月（夏月）與 12 月（非夏月）之模擬結果總結於表 5。

Table 5: EMS 最佳化結果

項目	2018 年 7 月	2018 年 12 月	單位
每月購電電費	190,670	178,211	新台幣
每月基本電費	100,020	76,770	新台幣
每月超約罰款	49,796	84,134	新台幣
每月總電費支出	340,486	339,114	新台幣
電網最高需量	487.57	581.37	kW
電網平均需量	61.94	82.95	kW
峰穀比 (PAR)	0.127	0.143	—
電池等效循環次數	31.21	35.37	次
再生能源利用率	91.08	98.46	%

Table 6: 傳統基準策略 vs. 分層 EMS 成本對比

ID	策略	總成本 (7 月)	總成本 (12 月)
B1	無配置電池情境	491,998	422,739
B2	時間電價規則調度	731,769	534,675
B3	固定負載門檻調度	851,846	547,370
B4	再生能源自用優先	392,341	422,739
B5	保守固定 SOC 策略	1,572,508	1,057,622
A	分層 EMS (MILP)	347,832	339,114

表 6 評估與五種基於傳統規則的基準策略 (B1–B5) 進行總成本對比。其中，B2 策略為電價低峰時充滿電、電價高峰完全放電；B3 為負載大於 SOC75% 即放電、小於 25% 即充電；B4 為優先使用再生能源；B5 則為 B3 上額外建構 SOC 不得小於 40%。

與 B2 比較時可發現本排程系統優勢在於能預測並保留太陽能發電所需之空間，避免提前購電充電後，導致太陽能發電再多出時直接被拋棄；而相較於太陽能優先規則 (B4)，本排程系統能解決太陽能發電高峰與電價高峰不一致之問題，透過妥善調適儲存或直接用盡太陽能發電，能減緩在尖峰時段購電之問題。

然而，本研究之排程仍具一定限制，首先，**電池容量應具一定規模**，若電池容量較小，與 B4 比較時，兩種策略均容易導致電池滿電而直接使用太陽能，並在電價高峰用電，無法突顯效果。此外，**太陽能發電應與用電量呈一定比例**，若太陽能發電量較小，則本策略與 B2 均能將太陽能發電完全用完，而不具優勢。

6 結論

在再生能源滲透率持續上升、企業用電成本壓力加劇的背景下，如何透過資料科學方法協助企業進行具經濟效益的能源管理，已成為橫跨資訊科學、能源工程與決策科學的重要議題。本研究針對此議題，建立一套整合「用電預測、發電預測與儲能排程最佳化」的三層式能源管理架構，並透過年度回測量化其經濟效益。在 2018 年的模擬情境下，分層式 EMS 的 7 月總電費相較於無配置電池基準策略 (B1) 由 491,998 元降至 347,832 元，降幅約為 29%；同時，其成本亦低

於五種傳統規則式基準策略，其中包含表現最佳的再生能源自用優先策略（B4：392,341 元）。此結果顯示，預測驅動的最佳化排程在企業能源管理上具備可量化的效益優勢。

在預測層方面，XGBoost 模型能有效捕捉用電量與太陽能發電量的時序變化及非線性關係，分別取得用電量預測 MAPE 15.00% 與發電量預測 $R^2 = 0.8599$ 的表現。值得注意的是，太陽能發電預測的整體 MAPE（36.10%）主要受到低發電時段小分母效應影響；若聚焦於儲能排程較具決策價值的高發電區間（2000–5000 Wh），MAPE 可降至 14.68%，顯示模型在關鍵決策時段的預測能力優於整體指標所呈現的結果。此外，本研究設計之兩個分位數模型，即用電量 q90 上界與發電量 q10 下界，在測試集上分別達到 90.88% 與 89.07% 的覆蓋率，與理論目標相差不到 1 個百分點，可為下游最佳化模型提供校準良好的風險估計輸入。

在最佳化層方面，雙層 MILP 架構同時納入時間電價、契約容量、SOC 限制、充放電功率、超約懲罰與電池衰退成本，並透過長期日前排程與短期 15 分鐘滾動調度的協同運作，使系統能在預測誤差存在的情境下仍維持穩定的決策品質。相較於傳統基準策略，本架構的優勢主要來自兩項設計：第一，模型能預測太陽能發電的時間分布，避免提前購電充電後導致發電高峰時段之餘電被迫棄置；第二，模型能銜接太陽能發電高峰與電價尖峰之間的時間落差，透過儲能將午間發電轉移至傍晚尖峰時段釋出。

本研究的方法論價值在於將預測模組與最佳化模組透過不確定性量化進行整合。傳統能源管理研究常將「預測準確度」與「排程效益」視為兩個獨立目標分別最佳化；相較之下，本研究透過分位數模型作為兩者之間的橋樑，使預測層不僅輸出平均情境下的點估計值，也提供高負載或低發電等保守情境的量化估計；最佳化層則可在追求期望成本最小化的同時，納入不利情境下的成本權衡。此設計使預測與排程不只是方法上的串接，而是在「不確定性量化」層面形成有機整合，構成本研究的主要方法貢獻。

然而，本研究結果仍受到若干限制影響。首先，太陽能發電資料來自歐洲電廠，與台灣的日照條件、氣候型態與季節變化存在差異。其次，用電與發電資料並非來自同一場域，因此需透過尺度調整（太陽能發電量倍數 18）進行匹配。最後，模型主要以預測點估計值作為確定性輸入，雖然已透過 q10/q90 分位數模型提供保守緩衝，但尚未在數學上對超約機率提供嚴格保證。因此，本研究之結論應理解為示範性參數設定下的方法論驗證，而非可直接套用至特定企業場域的部署結果。

未來研究可從兩個方向延伸。第一，從方法論驗證走向實務部署：若能取得台灣本地特定企業之配對用電與太陽能發電資料，並接入實際數值天氣預報系統，將可進一步評估本架構在真實部署情境下的可遷移性與經濟效益。第二，從工程式穩健性走向具數學保證的穩健性：本研究目前以 q10/q90 分位數作為不確定性緩衝，屬於工程實務上的穩健設計；未來可進一步升級為機率約束最佳化或分配穩健最佳化，使「超約機率不超過 ε 」等風險容忍條件能以數學形式直接納入最佳化模型，進而提升系統在統計意義下的穩健性保證。