

社群媒體旅遊業配文偵測研究

闕蕎蓁¹, 王相淳², 范侑芸³, 陳彥融⁴, 蔡易辰⁵

¹ 經濟系, B10303125

² 工管系, B11701137

³ 會計系, B11302305

⁴ 資管系, R14725001

⁵ 資管系, R14725049

August 30, 2026

更動內容

本研究針對老師回饋修改，更動之處以紅色進行標記。主要更動內容如下：

- 模型評估指標更動：F1-Score 自整體資料的加權平均 F1 改為針對業配文類別之 F1 值（第 9.1 節）
- 模型架構：將七個不同促購關鍵詞特徵合併為一個特徵；不採用 stacking 或 early fusion，不另外針對文章內容、標題內容進行 BERT 提取特徵，直接用其他特徵進行分類。而於評估模型表現後，發現其表現並未有進步，且因頁數限制，故無列出其詳細模型評估報告。（第 9.1 節末段）
- 特徵重要性排行：除原本 Gini Importance 外，新增 Logistic Regression 之係數等以供重要性更詳細之評估。（第 9.2 節整節更動）

Contents

更動內容	i
1 研究動機與重要性	1
1.1 資訊透明度與內容品質之挑戰	1
1.2 資料分析偏誤對觀光市場之影響	1
1.3 內容擴散機制與平台平衡	1
1.4 本研究之三大核心價值	1
2 文獻回顧	2
2.1 業配文與欺騙性評論研究	2
2.2 偵測方法與特徵工程	2
2.3 少數類別識別	2
2.4 旅遊領域使用者生成內容的情感分析	3
2.5 研究缺口	3
3 研究架構	3
3.1 資料收集與標註	3
3.2 多維度特徵工程	4
3.3 分類模型建構	4
4 研究資料取得	5
4.1 社群平台選擇	5
4.2 資料採集範疇	6
4.3 資料採集與樣本篩選策略	6
4.4 資料採集結果	6
5 業配文標記	6
5.1 雙軌標註程序與 LLM 仲裁機制	6
5.2 一致性檢驗	7
5.3 爭議仲裁	7
5.4 關鍵樣本擴充	7
6 特徵工程	8
6.1 社交互動特徵	8
6.2 文本特徵	8
6.3 促購關鍵詞特徵	9
6.4 留言特徵	9
6.5 作者帳戶資訊特徵	10

6.6	作者歷史行為特徵	10
6.7	文本嵌入特徵	11
7	業配文情緒特徵萃取	11
7.1	資料前處理	11
7.2	情緒特徵運算	12
8	分類模型	13
8.1	兩階段堆疊 (Stacking) 模型	13
8.2	特徵水平融合 (Early Fusion) 模型	13
8.3	資料不平衡處理技術	14
8.4	應用場景設計：內容管理與即時偵測	14
8.5	模型選擇	14
9	研究結果與成效分析	15
9.1	模型表現比較	15
9.2	特徵重要性綜合分析	17
9.2.1	Gini Importance 與 Logistic Regression 特徵評估	17
9.2.2	兩模型結果之交叉對比與綜合分析	18
9.3	閾值調整分析	19
9.4	實例展示	19
10	管理意涵與學術貢獻	20
10.1	社群平台治理與實務應用	20
10.2	提升觀光大數據決策品質	20
10.3	學術貢獻總結	20
11	結論與未來展望	20
11.1	結論	20
11.2	未來展望	21
	分工狀況	23

1 研究動機與重要性

在當前數位行銷環境中，社群媒體已成為消費者獲取旅遊資訊與進行決策的核心場域。然而，隨著網紅經濟與隱性行銷的崛起，大量未揭露的「業配內容」湧入平台。這些內容模糊了真實分享與商業廣告的界線，使得原本以真實經驗為基礎的內容開始產生偏差，不僅侵犯消費者的知情權，更對觀光市場的數據分析與平台生態造成深遠威脅。

1.1 資訊透明度與內容品質之挑戰

業配內容氾濫且缺乏明確標註，導致社群平台資訊品質大幅下滑。當商業驅動的誘導性訊息偽裝成個人經驗時，使用者難以判斷資訊的客觀性。建立即時偵測機制，是維護社群平台公信力與資訊透明度的必要基礎。

1.2 資料分析偏誤對觀光市場之影響

在觀光大數據分析中，若無法有效排除業配內容，將引發嚴重的「資料分析偏誤」。業配文章通常帶有刻意營造的正面情緒與特定的促購語義，若旅遊業者或觀光局將其誤認為真實旅客之回饋，將導致市場趨勢預測失準，誤導觀光發展策略與資源分配。

1.3 內容擴散機制與平台平衡

業配內容往往透過特定的擴散機制（如：完整包裝的行程描述、使用強烈推薦語氣）在短時間內獲取高曝光，放大其影響力。當這類內容在整體資訊環境中的比例逐漸提高時，將使一般使用者更難接觸到真實且多元的經驗分享。因此，需要平衡平台內容生態，確保真實內容不被商業操作所淹沒。

1.4 本研究之三大核心價值

- **技術創新性**：結合深度學習語義特徵與作者行為模型，建構高精準度的混合式偵測框架。
- **決策精準化**：為觀光研究者提供純淨的數據集，排除商業干擾，提升市場動態觀測的真實度。
- **管理自動化**：協助社群平台實施即時監測，落實廣告揭露規範，優化數位治理效能。

2 文獻回顧

本節將就四個相互關聯的研究脈絡進行文獻探討與回顧，分別是業配文與欺騙性評論的特徵與本質、偵測方法的特徵工程設計、少數類別識別和情感分析在旅遊使用者生成內容中的應用，最後再以我們觀察到的研究缺口作結。

2.1 業配文與欺騙性評論研究

針對欺騙性使用者生成內容的學術研究，最早由 Jindal 與 Liu (2008) 奠基。兩人分析亞馬遜平台逾 580 萬筆評論，建立了評論詐騙的三類分類架構：不實意見 (untruthful opinions)、僅針對品牌的垃圾評論 (brand-only spam)，以及非評論性內容 (non-reviews)，並指出評論詐騙在本質上有別於網頁垃圾郵件，需要截然不同的偵測技術。

Ott et al. (2011) 進一步以飯店評論為素材，建立首個公開可用的欺騙性評論金標準資料集，並整合心理語言學特徵與 n-gram 特徵，開發出準確率近 90% 的分類器。其研究揭示欺騙性評論的關鍵語言特徵：假評論傾向使用大量感官與空間性描述，卻缺乏真實旅行者才具備的具體細節。在贊助內容識別方面，Wojdyski 與 Evans (2016) 發現即使平台標示揭露標籤，仍有超過九成的讀者無法正確辨認原生廣告 (native advertising)，顯示業配內容刻意模仿真實使用者的表達方式，說明了自動化偵測工具的必要性。

2.2 偵測方法與特徵工程

既有研究一致將可用於辨別欺騙性或商業性內容的特徵分為三大類：文本特徵、行為特徵與混合特徵。文本特徵涵蓋極端正向情感、缺乏負面細節、促銷性用詞頻率、文章長度與圖文比例等語言與結構指標 (Lau et al., 2012)。行為特徵則包含發文頻率、帳號年齡、發文是否集中針對特定品牌或路線，以及正向評論在總發文中的佔比，研究顯示這類特徵具有相當強的預測能力 (Zhang et al., 2023)。

Zhang et al. (2023) 同時提出一套混合深度學習框架，結合行為敏感的卷積特徵抽取器與基於 Longformer 的上下文感知注意力機制，在 Yelp 真實資料集上達到當代最佳偵測表現。Cao et al. (2022) 則對圖神經網路 (Graph Neural Networks) 應用於假評論偵測進行系統性綜述，指出使用者、產品與評論之間的關聯性特徵能有效捕捉有組織性的操控行為——此特性對於偵測公關公司協調運作的業配文尤具參考價值。

2.3 少數類別識別

由於業配文在論壇整體文章中屬於少數群體，傳統監督式分類方法面臨嚴重的類別不平衡問題。近期研究以指令調校 transformer 模型 (instruction-tuned

transformers) 結合語言困惑度評分、自動編碼器重建誤差與語意偏移分析，在 Amazon 評論資料集上以零樣本 (zero-shot) 方式達到 0.945 AUC 的表現 (Kotha, 2025)。此無監督框架在標註資料難以大量取得的情境下尤具優勢，高度符合本研究爬取旅遊論壇文章、缺乏業配文標籤的實際處境。

2.4 旅遊領域使用者生成內容的情感分析

在旅遊評論的 NLP 應用方面，Ali et al. (2022) 對 TripAdvisor 逾 39,200 筆評論進行 LDA 主題建模與情感分析，建立了一套可複製的旅遊領域文本分析流程，涵蓋資料爬取、前處理、主題萃取與情感極性判斷等完整步驟。針對旅遊評論短文中情感分布不均的問題，Xu et al. (2020) 提出改良的多分類情感分析方法，強調有效特徵抽取對於提升分類準確度的關鍵作用。此外，Guizzardi et al. (2021) 針對旅遊評論有用性的研究發現，評論者的專業度、主觀程度與圖片使用習慣共同影響讀者對評論品質的判斷，這些維度同樣可作為區分真實遊記與業配文的潛在信號。

2.5 研究缺口

儘管假評論偵測與贊助內容識別在電商平台 (Amazon、Yelp) 及新聞媒體領域已有豐富研究，但目前尚無研究專門針對嵌入於中文社群旅遊論壇 (如 PTT、Dcard 等) 中的未標示業配文進行自動化偵測。此類平台具有幾項獨特挑戰，即文章為長篇遊記而非短評形式、社群語言慣例形成特殊的文體風格，且缺乏星級評分等行為信號。本研究即針對此缺口，結合情感特徵、文本結構特徵與使用者行為特徵，建立適用於旅遊論壇情境的業配文過濾模型。

3 研究架構

本研究的方法論旨在建立兩套自動化偵測架構，分別進行即時偵測以及對既有內容進行過濾，區分社群平台上的「一般旅遊分享」與「未標示業配文」，其架構主要分為三個核心階段：資料收集與標註、多維度特徵工程以及分類模型建構。

3.1 資料收集與標註

- **資料取得：**透過網路爬蟲自 Dcard 旅遊板取得原始文章，包含標題、內文、留言、社群互動資訊、媒體資訊與作者行為數據。
- **人工標註：**由兩位標註者針對 2,000 篇樣本進行二元分類（業配 T / 非業配 F），核心判準為「存在引導性購買行為」與「合理推測作者收受對價」。

- **爭議仲裁與擴充**：針對標註不一致的文章，利用 Claude LLM 進行輔助仲裁，並額外追加 73 篇業配樣本以緩解類別不平衡問題。
- **文本前處理**：使用正規表達式清洗網址、HTML 標籤，並進行斷詞與段落切片，以維持長文本的語意結構。

3.2 多維度特徵工程

研究整合了多面向的特徵以捕捉業配文的特殊模式：

- **文本與多媒體結構**：包含文章總字數、換行密度、顏文字比率、外部連結數、圖片 / 影片數量、圖文比例等資訊。
- **社交特徵**：讚數、收藏數、分享數等互動資訊。
- **留言特徵**：統計留言數量、短時間內的留言總數、留言深度、作者回覆數量等資訊。
- **促購詞與語意特徵**：定義了 7 大類促購關鍵詞（如 cta_click 引導點擊、promotion 優惠折扣、urgency 急迫感等），計算其在文中出現的頻率。
- **情感分析特徵**：使用多語系預訓練模型計算每個段落的情感期望值與波動度，用以辨識業配文中常見的「持續高度正向」或「先抑後揚」的情緒模式。
- **作者基本資訊及行為特徵**：包括是否為可疑帳號、是否為官方創作者等帳戶資訊，以及作者歷史發文頻率、發文時間間隔波動度、短時間大量發文程度、旅遊文佔比和看板分散程度等。

3.3 分類模型建構

本研究設計了兩種主要的模型融合路徑進行實驗對比：

1. 兩階段機率融合 (Stacking Meta-Learner)

- **第一階段 (Base Models)**：利用 BERT (ckiplab/bert-base-chinese) 提取標題與內文向量，訓練分類器產出文章為業配的機率值 (title_is_ad_prob, content_is_ad_prob)。
- **第二階段 (Meta Model)**：將上述機率值結合結構化特徵，輸入隨機森林 (Random Forest) 或 XGBoost 進行最終決策。

2. 特徵水平融合 (Early Fusion)

- 將 768 維的 BERT 向量經由 PCA 降維（如 64 或 128 維）。

- 將降維後的向量與所有結構化特徵水平合併，直接輸入模型進行訓練。

效能強化與決策：針對資料不平衡問題，採用過採樣 (如 SMOTE、ROS) 與權重調整。並透過閾值調整，測試不同判定閾值 (0.1~0.9)，分析對 Precision 與 Recall 之影響，以符合不同管理情境之需求。

4 研究資料取得

本章節將說明研究資料的建構過程，主要分為四個部分，首先闡述資料來源之社群平台的選擇方式，其次再次界定本研究設計的多維度特徵，再者說明資料獲取的實作方式，並說明必要的資料篩選處理，最後闡述資料取得結果。

4.1 社群平台選擇

本研究選擇 Dcard 作為主要資料來源，主要基於該平台在台灣數位社群中所具備的獨特生態、受眾代表性與文本價值，具體原因如下：

- **目標受眾與市場代表性：**Dcard 是台灣最具影響力的年輕族群社群平台之一，其核心用戶包含大學生與青壯年小資族，是台灣旅遊市場的主力消費者，亦是品牌端進行口碑行銷最核心的目標受眾，因此選擇 Dcard 能有效捕捉當前旅遊業數位行銷市場的真實生態。
- **主題看板分流：**Dcard 擁有劃分明確的特定主題看板，這種結構化的社群設計讓特定主題的討論與文本高度集中，研究者能夠精準鎖定特定領域的內容，在資料的篩選與整理上更具效率。
- **豐富的長文文本：**相較於 Instagram 或 Threads 等偏向短文字或純視覺呈現的社群平台，Dcard 累積了大量圖文並茂的長篇遊記或深度開箱文，無論是真實心得還是包裝過的行銷內容，這些長文本都提供了足夠的語意脈絡與細節，是深入分析行銷軌跡的絕佳樣本。
- **業配文的重災區：**Dcard 以用戶經驗分享為核心的平台特性，使其成為品牌端進行口碑操作與隱性業配的主要渠道，同時，相較於 PTT 鄉民對商業廣告極度敏感，導致行銷文本必須藉由暗樁蓄意推文或虛假發問來高度隱蔽，Dcard 用戶對於包裝成體驗心得的原生廣告有著出較高的包容力，使該平台的行銷內容得以用結構完整、語氣自然的敘事軟文呈現，建構出一個特徵顯著、極具辨識與分析價值的隱性業配生態。
- **高度社群互動性：**不同於痞客邦等傳統部落格網站多屬於作者單向輸出、讀者被動接收的模式，Dcard 具備更強烈的社群互動特質，透過文章底下的點

讚、收藏、分享與留言，使用者能與作者進行雙向互動，這種互動數據不僅反映了文章的影響力，也能呈現社群對該篇內容的真實反饋與信任度。

4.2 資料採集範疇

如前段所述，本研究設計了多維度的特徵，涵蓋文本與媒體結構、社交互動成效、留言時序或數量、商業用詞彙頻率以及情緒分析資訊，另有作者相關的帳戶資訊及行為特徵。這組特徵著重於文本排版模式與客觀的行為指紋，能有效勾勒出潛在商業操作與一般素人分享的本質性差異，為後續的偵測模型訓練奠定多維度的數據基礎。

4.3 資料採集與樣本篩選策略

在資料採集的實際執行上，本研究使用 Python 爬蟲技術，透過 Dcard 提供的 API 進行上述特徵相關數據的抓取。然而，Dcard 具有允許用戶選擇匿名發文的機制，這會對行為特徵分析帶來限制，即無法有效追蹤匿名文章的作者之相關特徵，因此為了確保資料集中所有樣本在特徵維度上的完備性與一致性，本研究在資料爬取階段設定篩選條件排除所有匿名發文的文章，僅保留非匿名發文的文本，避免因身分隱蔽導致的行為特徵缺失，並確保模型能獲得均一、完整的訓練資料。

4.4 資料採集結果

最終成功收集到 Dcard 旅遊板近期的 5,200 篇文章，在剔除掉文章內容為缺失或內含資訊過少（例如僅有一張或數張圖片等）的貼文後，總計收集到 5,081 篇有效文章，供後續分析使用。

5 業配文標記

5.1 雙軌標註程序與 LLM 仲裁機制

本研究從 Dcard 旅遊版蒐集到 5,081 篇文章，為了避免社交互動特徵因為文章本身互動性不高而失去鑑別力，以及業配文往往重視社群互動，因此以總留言數作為篩選指標，選取較高的 2,000 篇作為標註樣本，由兩位獨立標註者進行業配文二元分類（T/F）。為提升判定一致性，標註前由二人先行標註十篇試標樣本，並針對二人給出不同分類的文章進行討論，最終合議得出判定標準。

核心判斷為以下兩項，符合任一者標為 T（業配文）：

1. 存在引導性購買行為：文章中出現足以引導讀者消費之具體訊息，例如折扣碼、優惠碼、導購連結、官方訂購網址等。

2. 可合理推測作者收受對價：作者具體點名特定品牌、旅行社、業務、領隊、導遊或商家，且敘述方式呈現推薦、置入意圖者。

若文章明確聲明非業配，原則上採信作者並標為 F（非業配文）。判定範疇涵蓋金錢報酬、贊助產品、免費體驗、合作邀請等任何形式之互惠關係。

5.2 一致性檢驗

兩位標註者完成獨立標註後，計算研究之跨評分者信度 (Inter-rater reliability)，結果如表 1 所示：

Table 1: 跨評分者一致性檢驗結果

指標	數值
總樣本數	2,000
兩人標註一致筆數	1,890 (94.5%)
Observed agreement (P_o)	94.50%
Cohen's Kappa (κ)	0.67
一致性等級 (Landis & Koch, 1977)	Substantial agreement

考量業配文為少數類（佔樣本約 7.6%—10.9%），另計算 T 類別之獨立指標：對稱性 $F1 = 0.70$ 、Jaccard index = 0.54，顯示少數類之標註難度高於整體 Kappa 所反映之水準。標註者個別表現的事後分析顯示兩位標註者具有互補的偏誤特性（標註 A 偏高 precision、低 recall；標註 B 反之），此差異支持後續採用第三方仲裁而非單方標註之決定。

5.3 爭議仲裁

針對兩位標註者意見不一致之 110 篇文章（5.5%），研究團隊運用大型語言模型（Claude）依前述判定標準進行輔助仲裁。仲裁過程要求模型對每筆爭議文章輸出判定結果、信心度與簡短理由，仲裁結果經研究團隊全數覆核確認後作為該篇之 final label。最終 2,000 篇主樣本中業配文 182 篇（9.1%）、非業配文 1,818 篇（90.9%）。

5.4 關鍵樣本擴充

由於主樣本中業配文比例偏低（9.15%），為提升後續模型訓練之類別平衡，研究團隊另行追加 73 篇業配文章樣本。此補充樣本之標註程序如下：

1. 機器篩選：從 Dcard 旅遊版未標註之 3,000 篇文章中，利用機器學習先大致對其進行分類預測，篩選出業配文。

2. **人工標註**：由一位獨立標註者（非主樣本之兩位標註者）依與主樣本相同之判定標準（引導性購買行為與推測作者收受對價）進行人工判定。
3. **人工覆核**：標註結果由主樣本之第二位標註者進行覆核確認，以維持與主樣本一致之標註品質。

6 特徵工程

爲了全面捕捉社群貼文的特徵屬性並精準識別商業意圖，本研究建構了多維度的特徵工程框架，共分爲「社交互動」、「文本資訊」、「促購關鍵詞」、「留言資訊」、「作者資訊」以及「作者歷史行為」六大維度，以及代表文章本身含有資訊的「文本嵌入特徵 (embedding)」，以下詳細說明各個特徵的意涵：

6.1 社交互動特徵

捕捉讀者對貼文的直接反饋與擴散效應：

- `edited`：是否編輯過 (1 代表 True，0 代表 False)
- `commentCount`：直接留言數量，也稱爲主留言數量
- `totalCommentCount`：總留言數量，等同於主留言以及回覆主留言的子留言之總數
- `likeCount`：按讚數
- `collectionCount`：收藏數
- `shareCount`：分享數

6.2 文本特徵

著重於文章本身的架構排版、媒體豐富度與基礎文本統計：

- `wordCount`：文章字數 (中文字元數量)
- `text_length`：文章長度 (去除連結、多餘留白符號及 Emoji 後)
- `lfFreq`：換行符號密度，可反映排版風格
- `linkPerWord`：文章內的外部連結比例 (外部連結數量 / 文章字數)
- `utmLinkRatio`：文章內帶有 UTM 參數的外部連結佔所有連結的比例 (UTM 連結數量 / 外部連結數量)，可作爲行銷追蹤指標

- emojiPerWord: Emoji 符號的比例 (Emoji 數量 / 文章字數)
- withImages: 是否包含圖片 (1 代表 True, 0 代表 False)
- withVideos: 是否包含影片 (1 代表 True, 0 代表 False)
- imageCount: 圖片數量
- videoCount: 影片數量
- imageTextRatio: 圖片對文字比例 (每千字圖片數)
- videoTextRatio: 影片對文字比例 (每千字影片數)
- mediaTextRatio: 媒體對文字比例 (每千字媒體總數), 媒體包含圖片和影片
- expected_sentiment_value: 文章情緒分數 (後方第七章詳述)
- sentiment_volatility: 文章情緒的波動程度

6.3 促購關鍵詞特徵

合併標題與內文, 依據商業意圖將特定詞彙頻率獨立衍生為 7 大類特徵欄位:

- cta_click (導購點擊): 如「點我下單」、「傳送門」、「私訊」等詞頻。
- promotion (優惠資訊): 如「折扣碼」、「讀者優惠」、「買一送一」等詞頻。
- urgency (推薦/急迫): 如「手刀」、「必囤」、「種草」、「激推」等詞頻。
- disclosure (廣告揭露): 如「感謝邀請」、「合作邀約」、「sponsored」等詞頻。
- platform_brand (品牌連結): 如「kkday」、「klook」、「agoda」、「momo」等商家名稱詞頻。
- recommendation (誘導推薦): 如「真心推薦」、「私心推薦」等詞頻。
- lottery (行銷活動): 如「留言抽獎」、「文末抽獎」等詞頻。

6.4 留言特徵

分析貼文發佈後的互動時效性與深度, 用以評估社群熱度:

- authorReplyRatio: 作者的回覆數量 (包含作者直接留言和回覆其他留言) 占總留言數的比例

- `authorReplyLinkRatio`: 作者回覆內的外部連結數量對作者的回覆數量的比例
- `authorReplyUTMLinkRatio`: 作者回覆內帶有 UTM 參數的外部連結數量占作者回覆內的外部連結數量比例
- `subcomDepth`: 平均子留言深度 (子留言數量 / 主留言數量)
- `firstCommentTimeDiff`: 第一個主留言的時間戳和發文時間的時間差
- `first30MinCommentRatio`: 前 30 分鐘內的主留言及子留言數量佔總留言數量的比例

6.5 作者帳戶資訊特徵

用以識別發文者的身份屬性與帳號可信度：

- `authorUseNickname`: 發文者是否為匿名 (1 代表 True, 0 代表 False)
- `authorHasCreatorBadge`: 發文者是否具有創作者勳章 (1 代表 True, 0 代表 False)
- `authorHasOfficialCreatorBadge`: 發文者是否具有官方創作者勳章 (1 代表 True, 0 代表 False)
- `authorSuspicious`: 是否為可疑帳號 (如機器人或水軍預警指標)

6.6 作者歷史行為特徵

透過發文者過去的發文軌跡，建立長期的行為特徵：

- `timeDiffDays`: 最舊與最新的貼文之時間差 (天)
- `postCount`: 歷史總發文數
- `postFreq`: 歷史發文頻率 (篇 / 天)
- `maxPostsPerDay`: 最大單日發文數
- `maxPostsPer12h`: 最大 12 小時內發文數
- `postIntervalStd`: 發文時間間隔標準差 (天)
- `businessHourRatio`: 平日上班時間發文的比率
- `weekendRatio`: 周末發文的比率

- `travelPostRatio`: 旅遊板文章佔所有貼文的比例
- `forumVariety`: 所有貼文的看板之分散程度
- `forumEvenness`: 所有貼文的看板之分布均勻度
- `avgLikes`: 貼文平均讚數

6.7 文本嵌入特徵

利用 BERT 提取向量後，根據不同分類方法採用不同之特徵：

- 搭配分類模型產出業配文機率：
 - `title_is_ad_prob`: 標題為業配文之機率
 - `content_is_ad_prob`: 內容為業配文之機率
- 將 CLS 向量進行降維使用。

7 業配文情緒特徵萃取

為了量化並萃取文章的情緒特徵，我們建構了一套自動化情緒分析流程。如前述文獻回顧所探討，過往研究已明確指出，業配文與一般真實心得文在行文風格上具有顯著差異，其中最為核心的特徵之一便是「高度正向的情緒傾向」，撰文者為了推廣商品或服務，往往會刻意放大正面評價並淡化缺點。基於此一動機，情緒特徵的捕捉成為本研究辨識業配文不可或缺的關鍵環節。整個自動化萃取流程主要包含資料前處理，以及結合深度學習模型的情緒分數期望值運算。

7.1 資料前處理

在進行文本分析之前，必須先克服社群媒體非結構化資料的挑戰。為避免不必要的雜訊干擾模型的語意理解與特徵提取，我們透過一連串的正則表達式對原始文本進行清洗。在此階段中，系統會自動偵測並刪除文章中夾帶的超連結網址、HTML 標籤、電子郵件地址以及使用者可能不小心輸入的亂碼。

此外，針對社群平台（如 Dcard 等）常見的排版習慣，我們也將多餘的連續空白字元與換行符號進行壓縮，避免過長的空白消耗模型的處理長度限制。在過濾雜訊的同時，我們有系統地保留了中英文本體、數字以及常見的全半形標點符號。此舉不僅能維持文本中完整的句子結構與語氣停頓，更能幫助底層語言模型更精準地識別斷句與語意脈絡，確保後續情緒推論的穩定性與準確度。

7.2 情緒特徵運算

考量到台灣社群平台常出現中英夾雜，本研究採用具備跨語境理解與多語系處理能力的預訓練語言模型 tabularisai/multilingual-sentiment-analysis 進行推論。

然而，社群平台上的長篇文章往往會超出該預訓練模型預設的輸入長度限制。我們採取了段落切片（Chunking）策略，將每篇文章以 400 個字元為單位，循序拆分成數個相互獨立卻又保有局部上下文的文本段落。

針對每一個被獨立切分出來的單一段落，模型在推論後會同時輸出該段落屬於極負向、負向、中立、正向、極正向這五種情緒類別的機率分佈。為了將離散的分類機率轉換為連續的數值指標，我們將這五項類別依序對應為 1 至 5 分，並利用機率加權的期望值算法，計算出該段落的情緒期望值 (Expected Score)，此一作法相較於單純取最大機率的類別，更能細緻地保留模型對於模糊情緒的信心程度。

最後，藉由彙整單篇文章內所有段落的期望分數並計算其平均，我們得以精準量化並萃取出代表該篇文章的核心情緒特徵：expected_sentiment_value，此特徵為介於 1.0 至 5.0 之間的連續變數，數值愈高代表文章總體情緒愈偏向極度正面，同時計算各個段落情緒分數的標準差來代表情緒的波動程度 (sentiment_volatility)。我們將這兩個連續變數作為後續機器學習分類任務的關鍵輸入特徵，用以捕捉業配文異常高昂的讚譽傾向或是太過強硬的情緒轉折。圖 1 為本研究全體文章資料集之總體情緒分數分布圖，進一步展示了情緒特徵在資料中的實際分佈型態。




Figure 1: 情緒分數分布圖

8 分類模型

本研究設計多組實驗，用以評估不同特徵融合架構、不平衡處理技術、以及應用場景對業配文偵測之效能影響，主要實驗矩陣如表 2 所示。

Table 2: 模型實驗評估項目矩陣

評估項目	1	2	3
特徵融合架構	兩階段堆疊	特徵水平融合	-
資料不平衡處理	參數設定 (權重調整)	SMOTE (過採樣)	ROS (隨機過採樣)
應用場景	既有內容管理	即時偵測 (發文當下)	-

8.1 兩階段堆疊 (Stacking) 模型

本架構旨在結合深度學習的文本語意表徵與傳統機器學習的結構化特徵，建立一個整合分類系統。其核心分為兩階段：

第一階段：語意機率生成 (Base Model Layer)

- **BERT 語意提取**：利用 `ckiplab/bert-base-chinese` 預訓練模型，分別提取標題與內文的 768 維 CLS 向量。
- **預測機率產出**：利用 Stratified 5-Fold 交叉驗證技術，訓練 Logistic Regression 或 SVM 分類器，生成標題與內文為業配文的 OOF (Out-of-Fold) 預測機率值 (`title_is_ad_prob`, `content_is_ad_prob`)，以避免第二階段訓練時產生資料洩漏。

第二階段：特徵融合與決策 (Meta-Learner Layer)

- **特徵整合**：將第一階段產出的 2 個語意機率值，與結構化特徵（如促購詞頻、發文頻率、情感波動度等）進行水平合併，形成輸入特徵矩陣。
- **元學習器測試**：評估 Random Forest、XGBoost 與 LightGBM 等集成演算法的分類效能。

8.2 特徵水平融合 (Early Fusion) 模型

相對於二階段堆疊架構，此路徑嘗試在原始特徵層級進行融合，以保留最完整的向量資訊：

- **PCA 維度壓縮**：由於 768 維的 BERT 向量直接合併會造成特徵空間過於稀疏，本研究利用 PCA 將標題與內文向量分別降維至 64 與 128 維以及 128 維與 256 維。
- **水平拼接**：將降維後的文字向量與 52 個結構化特徵直接拼接，形成高維矩陣，並由 XGBoost, LightGBM 等模型直接學習不同維度間的關聯。

8.3 資料不平衡處理技術

由於業配文在原始資料中僅佔約 12%，屬於極少數類別，本研究實作以下技術以優化模型對業配文的召回率：

- **SMOTE**：在訓練過程中合成虛擬的業配文樣本，平衡類別分布，實驗顯示此方法能顯著提升隨機森林模型的 AUC 表現。
- **ROS (Random Over-sampling)**：透過隨機重複少數類樣本，強化模型對業配特徵的記憶。
- **代價敏感學習**：透過調整模型參數（如 `scale_pos_weight` 或 `class_weight`），增加誤判業配文的懲罰權重。

8.4 應用場景設計：內容管理與即時偵測

本研究針對實際應用端區分為兩種實驗情境：

1. **既有內容管理**：使用包含發文後產生的社交互動特徵（如 `likeCount` 按讚數、留言數）進行預測。適用於平台定期審核或觀光數據校正。
2. **即時偵測**：嚴格剔除社交互動相關和留言相關等「發文後」才能產生的數據，僅保留「發文當下即可知」的資訊，如文章字數、圖文比、促購詞頻率、作者資訊等 42 個特徵，驗證模型在「文章發布後」立即進行過濾的可行性。

8.5 模型選擇

為了找出分類能力最佳的模型，本研究採取廣納不同學習範式再擇優使用的策略，挑選出 Logistic Regression、SVM (Support Vector Machine)、Random Forest、XGBoost 以及 LightGBM 五種具代表性的機器學習演算法進行效能評估與比較，挑選原因如下：

- **Logistic Regression**：作為結構較簡單的基準模型，具備高可解釋性與極快的運算速度。

- **SVM**：擅長處理高維度特徵，在小樣本的文本特徵空間中，能透過尋找最大邊際超平面展現優異的泛化能力。
- **Random Forest**：採用 Bagging 機制，藉由整合多棵獨立決策樹之結果，有效降低資料中雜訊所引起的過擬合風險，對極端特徵具備高度魯棒性。
- **XGBoost**：具備精密的防過擬合與糾錯機制，擅長對特徵進行複雜的交叉比對，在僅有小樣本不平衡資料中，能展現出極強的精準抓取能力。
- **LightGBM**：採用獨特的切分與生長策略，能在保持與 XGBoost 同等強大分類效果的同時，大幅降低資源需求並提升資料訓練的運算速度。

本研究未採用神經網路模型，主因在於該演算法通常需要大規模的資料方能較好的擬合，面對本研究僅 2,000 出頭篇的小樣本且不平衡資料，容易產生嚴重過擬合，且針對本研究構建的大量結構化數值特徵，樹狀集成模型在實務上的擬合能力與運算效率皆優於神經網路，故選擇以機器學習演算法作為核心。

9 研究結果與成效分析

9.1 模型表現比較

本研究以 **F1-Score** 作為主要模型選擇指標，並輔以 AUC 與 Accuracy 進行綜合比較。由於業配文屬於少數類別，單純 Accuracy 容易受到類別不平衡影響，因此 F1-Score 較能反映模型在 Precision 與 Recall 之間的平衡表現。

本研究發現，在兩階段堆疊的第一階段中，標題與內文表現最佳之模型分別為 RBF SVM (Non-linear) 與 Logistic Regression，其 AUC 達到 0.83 與 0.87，顯示產出之機率具有可信度。

而本研究也針對不同架構與相異不平衡處理技術進行評估，表 3 與表 4 分別彙整內容管理與即時偵測兩種應用場境下，以**業配文類別的 F1-Score**為評估標準，各主要搭配方法下表現最優之模型成效：

Table 3: 內容管理模型效能表現比較

架構	最佳模型	不平衡處理	Accuracy	AUC	F1-Score
Stacking	Random Forest	ROS	0.920	0.892	0.607
Stacking	Random Forest	參數設定	0.929	0.892	0.603
Stacking	Random Forest	SMOTE	0.916	0.895	0.586
Early Fusion	LightGBM	權重調整	0.893	0.839	0.518
Early Fusion	SVM (poly kernel)	ROS	0.909	0.878	0.595

Table 4: 即時偵測模型效能表現比較

架構	最佳模型	不平衡處理	Accuracy	AUC	F1-Score
Stacking	Random Forest	SMOTE	0.920	0.895	0.593
Stacking	Random Forest	參數設定	0.899	0.888	0.597
Stacking	Random Forest	ROS	0.885	0.890	0.591

數據顯示，在內容管理情境下，採用 **Stacking (Random Forest + ROS)** 架構在綜合指標 (尤其是 AUC 與 F1-Score) 上表現最佳，雖然部分模型在單一指標上具有相近或略高的表現，但其在整體表現上較為均衡，能同時維持良好的分類能力與少數類別辨識效果，因此適合作為內容管理場景下的主要模型。在即時偵測情境下，**Stacking (Random Forest + SMOTE)** 整體表現最佳。相較於其他模型，其在各項指標之間取得較佳平衡。

這顯示出不論是否移除社交互動與留言等發文後特徵，Stacking 架構都能保有穩定的偵測能力。我們認為原因在於 Stacking 能有效整合 BERT 提取的深層語意機率與作者行為特徵，若使用 Early Fusion 可能會因為降維造成一些資訊損失、或因 BERT 生成的 representation 維度較高而稀釋其他特徵，因此本研究在特徵又較內容管理更少的即時偵測情況下未使用 Early Fusion 模式。

以下為在平台方的內容管理場景下，表現最佳模型 Random Forest + ROS 的詳細分類報告，如表 5 所示：

Table 5: Random Forest + ROS 詳細分類報告

類別 / 指標	Precision	Recall	F1-Score	Support
非業配 (F)	0.959	0.963	0.961	1814
業配文 (T)	0.617	0.590	0.603	183
Accuracy	—	—	0.929	1997
Macro avg	0.788	0.777	0.782	1997
Weighted avg	0.928	0.929	0.928	1997

可以看見模型對非業配文的辨識表現明顯優於業配文，主要原因在於資料集中的非業配文樣本數遠高於業配文，使模型在判別少數類別時面臨較大挑戰，抑或是兩類文本之間的分類邊界較為模糊，導致 Precision 與 F1-Score 較低。儘管如此，ROS 技術仍顯著提升了模型對少數類別 (業配文) 的捕捉能力，使其在維持高準確率的同時，業配文的 Recall 提升至 0.667。此結果顯示模型雖仍存在正類辨識難度，但已能有效提高潛在業配文的偵測率，符合內容管理情境中偵測可疑文章的需求。

除上述架構之模型，本研究另針對「促購關鍵詞特徵融合」與「不針對內文、標題內容進行 BERT 提取特徵，只利用其他特徵來進行分類之模型」進行業配文偵測，然而其模型表現並未有顯著進步，數據面來說，若不採取 stacking 或 early

fusion，也就是不放入文章與標題內容特徵（第 6.7 節文本嵌入特徵），則其業配文之 precision 與 F1-Score 皆會低於 0.5，故仍採用本研究原始方法。

9.2 特徵重要性綜合分析

本研究同時採用 Random Forest 之 Gini Importance 與 Logistic Regression 之自變數係數，從不同模型視角評估識別業配文的關鍵指標。

9.2.1 Gini Importance 與 Logistic Regression 特徵評估

透過隨機森林模型判定，業配文的前 10 大關鍵特徵與不純度貢獻度如下：

1. content_is_ad_prob（內文業配機率）：0.1887
2. title_is_ad_prob（標題業配機率）：0.0878
3. wordCount（文章字數）：0.0607
4. likeCount（按讚數）：0.0465
5. postFreq（歷史發文頻率）：0.0457
6. postIntervalStd（發文時間間隔標準差）：0.0447
7. imageCount（圖片數量）：0.0384
8. collectionCount（收藏數）：0.0378
9. text_length（純文字字數）：0.0335
10. expected_sentiment_value（情緒分數）：0.0292

另根據 Logistic Regression 模型之特徵權重絕對值排序，前十大重要特徵與統計顯著性如表 6 所示。

Table 6: Logistic Regression 前十大重要特徵與顯著性

排名	特徵名稱	權重	方向	顯著性
1	content_is_ad_prob	0.7152	正向	顯著
2	maxPostsPerDay	0.4892	正向	不顯著
3	videoCount	-0.4478	負向	不顯著
4	title_is_ad_prob	0.3849	正向	顯著
5	expected_sentiment_value	0.3604	正向	顯著
6	travelPostRatio	-0.3429	負向	不顯著
7	forumVariety	-0.2904	負向	不顯著
8	imageTextRatio	-0.2859	負向	不顯著
9	maxPostsPer12h	-0.2855	負向	不顯著
10	commentCount	-0.2809	負向	不顯著

9.2.2 兩模型結果之交叉對比與綜合分析

綜合上述數據，Dcard 旅遊版業配文核心特性可歸納為以下四大面向：

1. **語意與促購特徵的決定性影響**：兩大模型均指出，由 BERT 產出的語言機率特徵具有最強的解釋力。
 - `content_is_ad_prob` 在 Gini Importance 中高居第一 (0.1887)，在 Logistic Regression 中亦展現最高的正向權重 (0.7152) 且達統計顯著；`title_is_ad_prob` 同樣在兩模型中名列前茅且具顯著性。這證實業配文存在相對穩定的語言模式，深度學習能有效捕捉此類非自然分享的語意。
 - 於 Logistic Regression 中達統計顯著 ($p < 0.05$) 的促購詞特徵 (如導購詞頻 `cat_freq_cta_click` 與品牌名稱頻率 `cat_freq_platform_brand`)，進一步反映出業配文常見的商業推廣行為。
2. **情緒表達與內容結構的高度精修**：業配文在篇幅與情感上呈現高度刻意的特徵，用以達到宣傳效果。
 - **高度正面情緒**：情緒期望值 (`expected_sentiment_value`) 在隨機森林與 Logistic Regression 皆表現突出且具統計顯著性。由於業配通常著重於優點並避免負面評論，因而呈現顯著的正向情感偏向。
 - **豐富的內容結構**：隨機森林中總字數 (`wordCount`)、圖片數 (`imageCount`) 與純文字數 (`text_length`) 均位居前茅，顯示業配文為了達到宣傳效果，通常會配置較長的篇幅與精修圖片，與一般使用者隨手紀錄的簡短貼文有顯著區別。
3. **作者發文行為軌跡與專注度**：歷史發文行為能提供強大的帳號識別信號，區辨商業創作者與真實用戶。
 - **專業帳號行為**：隨機森林的歷史發文頻率 (`postFreq`) 與發文時間間隔標準差 (`postIntervalStd`) 排名靠前；Logistic Regression 中 `maxPostsPerDay` (0.4892) 亦高居第二，顯示部分商業帳號具備高產出、高度組織性與密集發文的行為軌跡。
 - **真實分享者特徵**：Logistic Regression 中 `travelPostRatio` (-0.3429) 與 `forumVariety` (-0.2904) 皆為負向 (雖未達顯著，但仍具方向解釋力)。說明長期深耕旅遊版或跨足多元主題 (感情、美食) 的使用者，多為真實旅遊愛好者，而非特定主題的商業接案帳號。
4. **社交互動數據的低穩定性**：按讚數 (`likeCount`) 與收藏數雖然在隨機森林排行前列，但 Logistic Regression 顯示，留言數 (`commentCount`) 權重為負

且未達統計顯著水準。這證實了社交互動指標易受發文時機、熱門話題、平台推薦機制或人為操作（如買讚、假互動）等隨機因素干擾。相較於語意與行為特徵，互動數據的穩定性較低，較難單獨作為有效辨識未標示業配文的依據。

9.3 閾值調整分析

管理決策可依據不同應用場景調整模型之判定閾值。當閾值設定為 0.5 時，模型整體 F1-Score 表現最佳，可在 Precision 與 Recall 間取得較佳平衡；而當閾值提高至 0.8 時，Precision 可提升至 0.811，但 Recall 會下降至 0.235，代表模型雖能更準確地判定業配文，但可偵測出的業配文章數量將明顯減少。

此結果顯示社群平台在實際應用時需於 Precision 與 Recall 間進行權衡：較高的閾值有助於降低誤判一般文章的風險，但同時也可能漏掉部分業配內容；相對地，較低的閾值則能提升業配文的偵測率，但可能增加誤判情形。因此，平台可依據實際管理需求與使用情境，選擇適合的判定閾值。

9.4 實例展示

此業配文偵測模型有高於五成之準確度，以下是其中一篇被模型偵測為業配文且標注者也認同其為業配文之案例(文中所有圖片已由原始網址轉成代號)：

< 圖片 1 >

在那裡第一次接觸到 acroyoga
那裡的人都很親切，完全初學也沒問題！

< 圖片 2 >

還有一部分是戶外的，單槓、Ring 都能在這練習。

< 圖片 3 >

另外還有游泳池、冷水池、熱水池與桑拿可以恢復身體，旁邊也有按摩區可以付費按摩。

< 圖片 4 >

< 圖片 5 >

這裡也有附設餐廳跟吧台，餐廳連食物都很健康，超適合來這 build body。

< 圖片 6 >

< 圖片 7 >

< 圖片 8 >

愛運動的小夥伴們一定要來這裡體驗一下！！

此篇文章並不是非常明顯的業配內容，但由於其情緒表現通篇高度正面且具推

薦語氣，同時圖文比例偏高，且較少撰寫者個人感受，因此被標注者認為是業配文章，而模型也順利將其偵測為業配文。

10 管理意涵與學術貢獻

10.1 社群平台治理與實務應用

本偵測框架可無縫整合至平台後端，針對偵測出的潛在業配內容，自動觸發「未揭露廣告提醒」或進行流量標註。這有助於推動網紅行銷的合規化，重建使用者對內容真實性的信任。

10.2 提升觀光大數據決策品質

透過本模型精準排除商業操作數據，觀光研究者能獲得更純粹的消費意向與景點評價數據。這對於分析真實的旅遊趨勢、制定精準的行銷分配政策具有重大價值。

10.3 學術貢獻總結

本研究驗證了結合 **BERT 語義向量**、**人工設計專家特徵**與 **Stacking 融合架構** 在特定領域欺騙性內容偵測上的有效性，並將業配文偵測對象延伸至中文社群旅遊論壇，補足此類長文本、圖文式內容在自動化辨識研究上的不足。此外，本研究同時納入文本語意、情緒特徵、作者行為與社群互動資訊，提供一套較符合社群平台實際情境的混合式偵測框架，可作為後續研究之參考。

11 結論與未來展望

11.1 結論

本研究以社群媒體旅遊業配文偵測為核心目標，針對 Dcard 旅遊板文章建構一套自動化分類流程。研究首先透過資料爬取與人工標註建立分析基礎，並採用補充樣本方式緩解業配文樣本不足的問題。在特徵設計方面，本研究整合文本結構、社交互動、留言特徵、促購關鍵詞、作者資訊、作者歷史行為、情緒特徵與 BERT 語意特徵，嘗試從多個面向捕捉業配文與一般旅遊分享之間的差異。

模型實驗結果顯示，結合 BERT 語意機率與結構化特徵的 Stacking 架構，在內容管理與即時偵測兩種應用情境下皆能取得穩定表現。其中，內容管理模型適合用於平台定期審核與既有內容篩選，即時偵測模型則僅使用發文當下即可取得的特徵，展現出模型應用於即時預警與初步過濾的可行性。特徵重要性分析也進一

步顯示，文本語意特徵、文章長度、社群互動與作者行為資訊皆是判斷業配文的重要依據，說明業配文偵測並非僅能依賴單一促購詞或連結特徵，而需要結合語意、結構與行為訊號進行綜合判斷。

整體而言，本研究證明混合式特徵工程與機器學習模型能有效應用於中文社群旅遊業配文偵測。此成果不僅能協助社群平台辨識潛在未揭露廣告內容，提升內容管理效率與資訊透明度，也能為觀光大數據分析提供較乾淨的資料來源，降低商業操作內容對旅遊趨勢判讀與決策制定造成的偏誤。因此，本研究在社群平台治理、旅遊資訊品質維護與中文業配文自動化偵測方法上，皆具有一定的實務與研究價值。

11.2 未來展望

後續研究可進一步發展多模態偵測技術，將旅遊文中關鍵的圖片視覺特裝與文本進行深度融合，以應對日益精進、將商業訊息嵌入圖像中的隱性營銷手法。此外，針對資料不平衡問題，未來可探索利用合成少數過採樣技術 (SMOTE) 的進階變體，以期在維持高精準度的同時提升模型的全面召回能力。

References

- [1] Jindal, N., & Liu, B. (2008). Opinion spam and analysis. *Proceedings of the 1st ACM International Conference on Web Search and Data Mining (WSDM 2008)*, 219—230.
- [2] Ott, M., Choi, Y., Cardie, C., & Hancock, J. T. (2011). Finding deceptive opinion spam by any stretch of the imagination. *Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics (ACL 2011)*, 309—319.
- [3] Lau, R. Y. K., Liao, S. Y., Kwok, R. C., Xu, K., Xia, Y., & Li, Y. (2012). Text mining and probabilistic language modeling for online review spam detection. *ACM Transactions on Management Information Systems*, 2(4), Article 25.
- [4] Wojdyski, B. W., & Evans, N. J. (2016). Going native: Effects of disclosure position and language on the recognition and evaluation of online native advertising. *Journal of Advertising*, 45(2), 157—168.
- [5] Zhang, D., Li, W., Niu, B., & Wu, C. (2023). A deep learning approach for detecting fake reviewers: Exploiting reviewing behavior and textual information. *Decision Support Systems*, 165, Article 113895.
- [6] Cao, Q., Shen, H., Cen, K., Ouyang, W., & Cheng, X. (2022). Graph learning for fake review detection. *Frontiers in Artificial Intelligence*, 5, Article 922589.
- [7] Ali, T., Omar, B., & Soulimane, K. (2022). Analyzing tourism reviews using an LDA topic-based sentiment analysis approach. *MethodsX*, 9, Article 101894.
- [8] Xu, X., Wang, X., Li, Y., & Haghighi, M. (2020). Research on sentiment classification of online travel review text. *Applied Sciences*, 10(15), 5275.
- [9] Guizzardi, A., Pons, F. M. E., Ranieri, E., & Vici, L. (2021). What drives the helpfulness of online reviews? A deep learning study of sentiment analysis, pictorial content and reviewer expertise for mature destinations. *Journal of Destination Marketing & Management*, 19, Article 100549.
- [10] Kotha, S. (2025). Multi-modal anomaly detection in review texts with sensor-derived metadata using instruction-tuned transformers. *Sensors*, 25(22), 7048.

分工狀況

Table 7: 團隊成員工作分工表

組員姓名	工作內容
闕蕎蓁	關鍵詞與文本嵌入特徵提取、分類模型架設、文件與簡報製作
王相淳	資料標註、上台報告
范侑芸	資料標註、簡報製作
陳彥融	資料爬取、特徵定義、整理原始資料成資料集
蔡易辰	情緒分析特徵擷取、補充樣本資料標註、上台報告